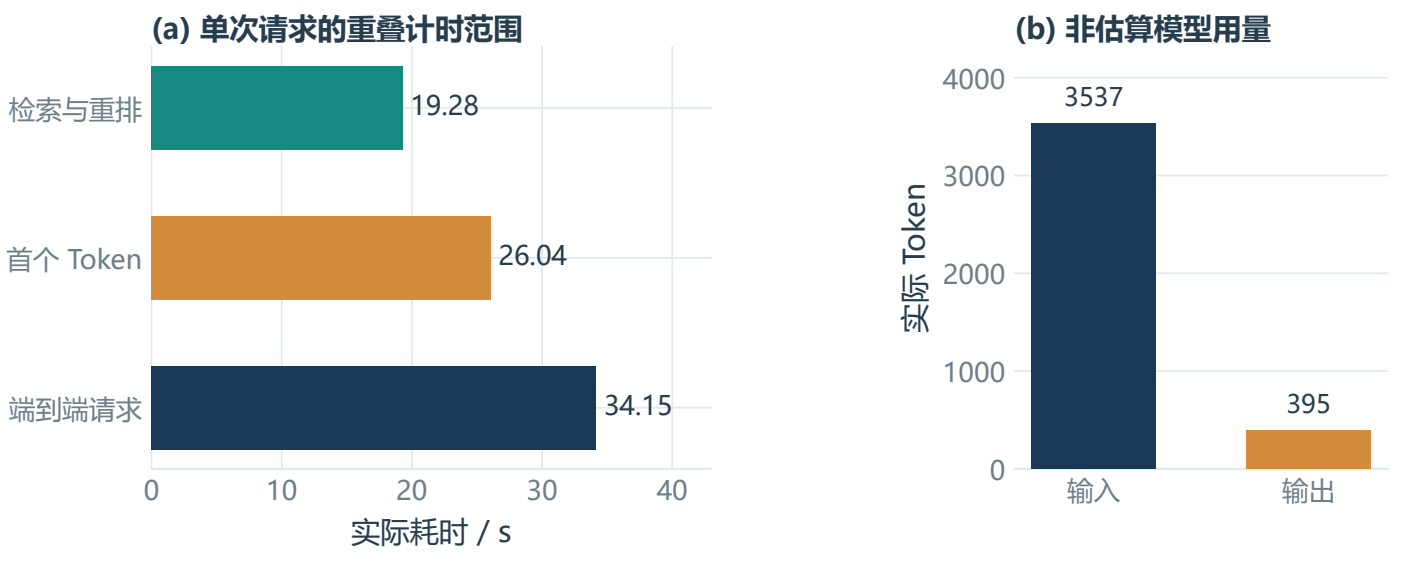
(a) 单次请求的重叠计时范围
检索与重排
19.28
首个 Token
26.04
端到端请求
34.15
0
10
20
30
40
实际耗时 / s
(b) 非估算模型用量
4000
3000
2000
1000
0
实际 Token
3537
395
输入
输出