# 南京农业大学

# 课程考核情况表

2026—2027 学年第 1 学期

| | |
|---|---|
| 学院 | 智慧农业学院（人工智能学院） |
| 课程名称 | 生产实习 |
| 学分 | 1 |
| 考核方式 | 课程报告 |
| 考核内容 | 智能科研助理——基于 RAG 与 Agent 的论文知识库问答系统 |
| 学生姓名 | 赵志国、林骋、林弟伟 |
| 成绩 | |
| 教师签名 | |

实际提交日期：_____ （提交时填写）

# 生产实习课程报告

## 智能科研助理

### 基于 RAG 与 Agent 的论文知识库问答系统


| 姓名 | 班级 | 学号 |
| --- | --- | --- |
| 赵志国 | 人工智能 231 | 11523122 |
| 林骋 | 人工智能 231 | 11523121 |
| 林弟伟 | 人工智能 232 | 11523120 |

智慧农业学院（人工智能学院）

南京农业大学


编制日期：2026 年 10 月 15 日

# 摘要

论文知识库问答既需要覆盖原文证据，也需要控制生成过程中的事实归属、引用位置与工具调用。本项目面向通用论文阅读任务，构建由文档处理、混合检索、检索增强生成、手写 Agent 控制及评测记录组成的科研助理。系统支持多格式导入、三种分块策略、向量与 BM25 候选融合、交叉编码器重排、流式回答和物理页引用；使用原始 token-ID 分窗处理超长输入，并记录模型、索引和配置指纹。在视觉 Transformer 专题的 10 篇固定版本论文上建立 80 题评测集，区分 20 题开发集与 60 题测试集。历史 359 片段索引上的测试结果显示，向量检索、混合检索和混合加重排的 Hit@5 分别为 0.4167、0.4333 和 0.6167；CPU 重排同时带来较明显的时延代价。流畅性均分为 4.58，而完整性和引用支撑分别为 2.98 和 3.03，表明证据覆盖与断言约束仍是主要瓶颈。四题提示词对照中，引用支撑均分由 2.50 增至 3.50，正确性均分不变；该结果仅作为小样本探索性观察。本地标准模型流程完成 33 类实际检查，覆盖论文导入、真实生成、引用预览及记录保存。

**关键词**：检索增强生成；工具调用；论文知识库；混合检索；可追溯评测

# 目 录

**摘要** **1**

**一 项目概述** **4**

1.1 项目背景 . . . . . 4

1.2 任务定义与项目目标 . . . . . 4

1.3 技术栈与实现边界 . . . . . 4

**二 团队分工说明** **5**

**三 模块交付物清单** **5**

**四 技术实现记录** **8**

4.1 体系结构与数据流 . . . . . 8

4.2 文档解析分块与超长输入处理 . . . . . 8

4.3 混合检索与重排算法 . . . . . 9

4.4 证据约束生成引用与缓存 . . . . . 10

4.5 手写 Agent 与八工具协同 . . . . . 11

4.6 交互实现与功能区说明 . . . . . 13

4.7 评测设计与指标定义 . . . . . 15

4.8 解析分块模型与向量库实验 . . . . . 18

4.9 三档检索消融与参数迭代 . . . . . 22

4.10 答案质量生成参数与提示词比较 . . . . . 26

4.11 Agent 效率与本地运行验收 . . . . . 30

4.12 Bad Case 分析与优化边界 . . . . . 33

**五 技术设计文档** **35**

5.1 模块接口与持久化 . . . . . 35

5.2 配置与可复现控制 . . . . . 35
5.3 隔离错误与安全边界 . . . . . 37
5.4 扩展设计的价值与限制 . . . . . 37

**六 总结与展望** **37**
6.1 项目总结 . . . . . 37
6.2 困难与解决过程 . . . . . 38
6.3 研究限制与后续工作 . . . . . 38

**参考文献** **38**

**七 附录** **41**
7.1 实际代码结构与复现环境 . . . . . 41
7.2 本地运行与重新验收 . . . . . 42
7.3 证据索引与课程要求对应 . . . . . 43
7.4 图表与源文件编译 . . . . . 44

# 一 项目概述

## 1.1 项目背景

科研阅读需要在多篇论文之间核对方法、训练条件和实验结果。仅依赖语言模型记忆容易产生事实与来源不一致的问题，单纯关键词检索又难以直接完成归纳和比较。因此，项目将可定位的论文证据检索与受约束的生成、计算和工具协同结合，以支持可复查的科研问答。

## 1.2 任务定义与项目目标

设当前工作区论文集合为 $\mathcal{D}$，问题为 $q$，有界会话历史为 $H$，系统输出为

$$(a, \mathcal{C}, \mathcal{L}) = F(q, H, \mathcal{D}; \theta), \tag{1}$$

其中 $a$ 为答案，$\mathcal{C}$ 为绑定原文位置的来源集合，$\mathcal{L}$ 为实际执行与资源记录，$\theta$ 包含模型、索引和生成配置。项目目标是使文档可导入、证据可检索、回答可引用、动作可观察、实验可复核。检索分数不解释为事实正确性的概率，来源编号存在也不等价于该来源支持全部断言。

RAG 通过外部检索证据补充生成模型的参数知识 [1]；ReAct 提供动作与观察交替的工具使用范式 [2]。本文据此实现可检查的编排过程，而不是以现成 Agent 框架替代课程要求的核心控制逻辑。系统面向通用论文知识库，评测专题限定为视觉 Transformer 架构、训练与数据效率，不把专题限制固化为产品使用范围。

## 1.3 技术栈与实现边界

服务层采用 FastAPI，交互层采用 Streamlit，状态数据保存于 SQLite；文档适配器使用 PyMuPDF、pdfplumber、PyPDF2 及

python-docx。向量编码与交叉编码器推理由 Sentence Transformers 提供，向量存储适配 Chroma 与 FAISS，稀疏检索调用 BM25Okapi。本地生成通过 Ollama 调用 Qwen2.5-7B-Instruct 的 Q4_K_M 权重，实际模型标签为 `research-qwen:7b`。项目自行实现分块来源传播、RRF 融合、原 token-ID 窗口控制、引用规则审校、缓存准入和工具控制器。联网搜索属于课程可选能力，未将其作为八个本地工具之一。

## 二 团队分工说明

**表 1** 成员分工安排与约定贡献比例

| 角色 | 姓名 | 核心职责安排 | 模块 | 比例 |
|---|---|---|---|---|
| 检索与 RAG | 赵志国 | 文档处理、证据检索、生成与服务编排 | 文档与问答 | 40% |
| Agent 与工具 | 林骋 | 工具注册、路由、记忆及异常终止控制 | Agent | 30% |
| 交互与评测 | 林弟伟 | 页面流程、实验整理、文档与展示材料 | 集成与评测 | 30% |

表1的姓名、班级、学号与贡献比例依据小组提供的信息整理，比例合计 100%。职责细分为本报告采用的分工安排，提交前应由成员按实际工作确认。

## 三 模块交付物清单

交付状态区分代码实现、真实执行和评价来源。以下五表对应课程模块，不将“提供脚本”视为“已完成环境验收”。

**表 2** 模块一文档处理与检索交付物

| 交付项 | 状态 | 证据与范围 |
| --- | --- | --- |
| 多格式解析与三解析器 | 已实现 | PDF、DOCX、TXT、MD；10 篇论文的 30 次解析记录，E03 |
| 三类分块与长度比较 | 已实现 | 固定 256/512/1024、递归、句段边界；同 20 题 dev，E04 |
| 两类 Embedding 比较 | 已实现 | m3e 与 BGE-large-zh；生产另用 BGE-M3，E05 |
| 向量库与混合重排 | 已实现 | Chroma/FAISS、BM25、手写 RRF 及 CrossEncoder，E06—E08 |

**表 3** 模块二 RAG 问答交付物

| 交付项 | 状态 | 证据与范围 |
| --- | --- | --- |
| 提示词与上下文构造 | 已实现 | 预算控制、论文轮转、来源同步裁剪，E10 |
| SSE 与引用追溯 | 已实现 | 增量回答、物理页预览、原件哈希核对，E14 |
| 缓存与失败处理 | 已实现 | 指纹约束准入、精确重复探针、显式降级，E12 |
| 生成参数质量比较 | 五条件各 4 题，E10 | |

**表 4** 模块三 Agent 交付物

| 交付项 | 状态 | 证据与范围 |
| --- | --- | --- |
| 手写执行控制器 | 已实现 | schema 校验、工具动作与观察、有界终止 |
| 八项本地工具 | 已实现 | 问答、元信息、比较、关键词、摘要、时间、计算和目录 |
| 记忆与错误恢复 | 已实现 | 会话隔离、窗口与摘录记忆、受限重试 |
| 路由与并行探针 | 已实测 | 5 个路由样本；20 次本地工具执行，E11、E12 |

**表 5** 模块四集成与交互交付物

| 交付项 | 状态 | 证据与范围 |
| --- | --- | --- |
| 四个工作台页面 | 已实现 | 论文库、问答、比较、实验与运行记录 |
| 会话及文档管理 | 已实现 | 上传进度、重试、元信息、会话搜索与导出 |
| 运行追踪与统计 | 已实现 | 状态、用量、模型与检索配置快照 |
| 本地标准模式验收 | 已通过 | 33 类实际检查、0 失败；单篇 CvT 独立工作区，E14 |

**表 6** 模块五评测与材料交付物

| 交付项 | 状态 | 证据与范围 |
| --- | --- | --- |
| 语料与评测题集 | 已建立 | 10 篇固定论文、80 题、四类问题，E01、E02 |
| 检索指标与 Bad Case | 已执行 | 三档 test60、四类错误、优化前后记录，E07、E15 |
| 答案质量评分 | 60 题评分已完成，E09 | |
| 文档及演示材料 | 已提供 | 报告、设计、手册、实验附件与演示稿 |
| Docker 部署 | 文件已提供 | 本报告采用本地验收 |

# 四 技术实现记录

## 4.1 体系结构与数据流

系统将文档处理路径与问答路径分开：前者形成可定位的片段和索引，后者在指定范围内检索、编排证据并产生回答。SQLite 保存文档、会话、运行与实验元数据，向量库保存可按工作区过滤的编码结果。原文物理页与字符来源贯穿整个流程，使回答中的来源编号可以回到实际文件，而不是停留在模型生成的参考文献文字。图1展示模块及其数据关系。

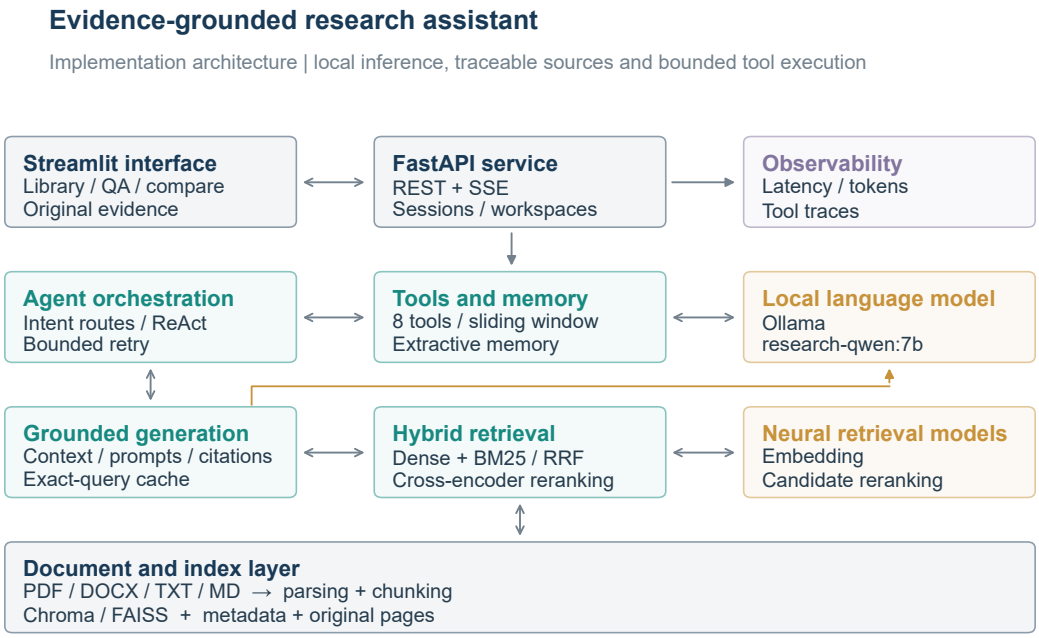



**图 1** 论文知识库与 Agent 系统的数据流。原文位置、配置指纹和执行记录与正文处理链路共同保存；框架能力与项目控制逻辑在实现中分开。

## 4.2 文档解析分块与超长输入处理

PDF 解析输出统一来源块。能够获取布局信息的适配器保留物理页与边界框，阅读顺序采用全宽块划分阅读带、带内先左后右的启发式方法。表格以逐行文本保存，公式保留可提取的 Unicode 及上标信息，跨页来源分别记录。这些处理适用于具有文本层的 PDF，

不能表述为通用 OCR、完整版面理解或无损公式重建。DOCX 按正文顺序读取段落和表格；缺失作者、年份或 DOI 时保留缺失状态。

固定窗口、递归边界和句段边界三类分块分别控制长度、优先保持文本边界及利用段落/句末结构。递归策略实际调用 `RecursiveCharacterTextSplitter` 提出边界，再检验字符偏移和原子结构约束。句段策略未使用 Embedding 模型预测语义边界，因此不将其描述为学习式语义切分。默认长度 512、重叠 64，单位是项目定义的汉字、英文词或独立符号，与模型原生 tokenizer 分别管理。

为避免模型输入超限时静默截尾，编码器直接在原始 token-ID 序列上分窗，扣除特殊 token 预算，不进行 decode 再 encode 往返。设第 $j$ 个窗口含 $w_j$ 个原始 token，模型输出 $f(x_j)$，片段编码为

$$u_j = \frac{f(x_j)}{\max(\|f(x_j)\|_2, \epsilon)}, \tag{2}$$

$$v(d) = \operatorname{norm}\left(\frac{\sum_{j=1}^{m} w_j u_j}{\sum_{j=1}^{m} w_j}\right). \tag{3}$$

实现覆盖全部窗口并检查输入约束；加权聚合并不等价于无限上下文编码。模型缓存版本、窗口策略版本与窗口上限纳入指纹，以阻止不同编码策略误用已有向量。

### 4.3 混合检索与重排算法

密集检索使用归一化向量内积；Chroma 的 cosine 距离转换为 $1 - \text{distance}$，FAISS 使用精确 `IndexFlatIP`。稀疏检索采用 jieba、中文二元组与技术标识英文切分后调用 BM25Okapi[3]：

$$B(q,d) = \sum_{t \in q} \widetilde{\mathrm{IDF}}(t) \frac{f(t,d)(k_1+1)}{f(t,d) + k_1(1 - b + b|d|/\overline{|d|})}. \tag{4}$$

实际默认 $k_1 = 1.5$、$b = 0.75$；原始 IDF 采用 $\log[(N - n_t + 0.5)/(n_t + 0.5)]$，负值按库实现替换为平均 IDF 的 0.25 倍。本文据实际实现描述公式，不改写为另一种恒正 IDF 形式。

项目手写 RRF 仅使用候选名次，以避免不同检索分数的量纲影响 [4]：

$$R(d) = \sum_{r \in \{\text{dense,BM25}\}} \frac{\mathbb{I}[d \in L_r]}{k_0 + \text{rank}_r(d)}. \tag{5}$$

名次从 1 开始，每路先去重，默认 $k_0 = 60$；同分按片段标识稳定排序。每路候选数默认 20，融合后保留候选池，再返回 5 条或进入交叉编码器。融合没有对原始分数做 min–max 归一化。

重排使用 BGE-reranker-base 联合编码问题与候选；长文档保留完整问题，以原 token-ID 窗口计算 logit 并取最大值：

$$z(q,d) = \max_j g(q,d_j), \qquad s(q,d) = \frac{1}{1 + \exp[-z(q,d)]}. \tag{6}$$

$s$ 是单调阈值分数；最大窗口聚合可能高估单个相关窗口的代表性。重排失败时保留 RRF 顺序并记录降级原因，避免把未执行的重排记为成功。生产环境采用 BGE-M3 编码 [5]，与模块实验中的 m3e 和 BGE-large-zh 比较分别报告。

### 4.4 证据约束生成引用与缓存

上下文构造扣除系统提示、历史、问题与预留开销后分配证据预算，按论文分组轮转以减少单篇来源挤占。裁剪正文时同步裁剪来源及页区间；预算采用保守字符估算，模型服务返回的真实 token 另行记录。默认上下文预算 4096、生产输出预算 768；生成对比实验为 256 输出 token，二者不可混同。

服务器给来源分配 `[S1]` 等编号，绑定文档、片段、物理页和可用边界框。生成后规则审校检查引用编号、数字对应和部分相邻页码

表达，但不证明语义蕴涵。无结果时明确标注普通模型回答，低相关度时提示核查，模型失败时保留失败状态或原文摘录降级状态。SSE 传递状态、来源、文本增量、用量与结束事件；多工具路径的综合回放与单一 RAG 的模型增量在事件中区分。

缓存首先匹配索引、模型、生成配置、文档范围、历史与提示词指纹，再检查问题匹配及相似度阈值。默认阈值 0.96，并约束数字、英文锚点、否定及意图一致；有待核查引用、时效或指代问题不写入缓存。索引变化使旧指纹失效。此机制降低错误复用风险，但一次精确重复探针不足以测量总体缓存命中率。

### 4.5 手写 Agent 与八工具协同

注册表对工具名称、必填参数、类型和长度执行 schema 校验。八项工具的作用见表7。

**表 7** 工具注册表及边界

| 工具 | 能力与限制 |
|---|---|
| knowledge_qa | 指定论文范围内的证据问答 |
| paper_metadata | 读取实际保存的题名、作者、年份等字段 |
| compare_papers | 两篇论文的结构化比较；条件不齐时不直接排名 |
| extract_keywords | 文档或输入的词频候选，不把词频当论文结论 |
| summarize_paper | 依据证据生成结构化摘要 |
| current_time | 返回实际系统时间 |
| calculator | 白名单算术 AST 解释，不执行任意 Python |
| paper_catalog_search | 查询当前本地论文目录，不冒充互联网搜索 |

Agent 的 System Prompt 将角色限定为基于本地论文库的科研助理，要求先调用工具查证，再依据已返回的来源回答。工具说明及参数 schema 由注册表附入模型请求；原生工具调用不可用时，仅接受包含 `tool_calls` 的严格 JSON 动作。提示词约束论文标识来自

当前范围、引用仅使用工具返回编号、独立动作可并行、依赖动作须等待观察，并禁止重复同参调用及隐瞒失败。论文正文和工具结果被视为数据；最终回答不输出内部思维链，数值比较须说明任务、数据划分与指标条件。这些约束与服务器的范围校验、动作去重及步数预算共同生效，不能仅凭提示词保证执行安全或内容正确。

控制器采用快捷路由与有界模型规划结合的实现。一般概念可走显式模型常识路径，单一论文事实问答进入流式 RAG；其余任务由动作和工具观察交替推进。两篇论文已被明确选定时，服务器固定比较范围，避免规划阶段编造文档标识。独立工具可在受限线程池并行，存在依赖的动作等待前一步结果；并非每个问题都执行多轮规划。规划不可用时采用透明的本地路由，不将快捷路径伪装为复杂 Agent 推理。

默认最多 6 步，限制单工具与请求总预算，按工具名和规范化参数检测重复动作。仅在原调用已结束且属于临时错误时允许有界重试；超时但仍运行的线程继续占用槽位，避免推测性副本。会话记忆由近期窗口与旧消息抽取摘录组成，默认最多 8 条近期消息、1400 个估算 token；派生记忆与原消息分开保存。公开日志只呈现动作、参数、结果、耗时和状态，不输出模型内部思维链。

**表 8** 范围与预算约束下的证据增强执行过程

| 步骤 | 执行逻辑 |
|---|---|
| 1 | 校验工作区和就绪文档范围，读取有界会话记忆。 |
| 2 | 判定普通模型、单一 RAG 或工具循环路径，并记录所选路径。 |
| 3 | 对知识检索生成 dense 与 BM25 候选，按名次执行 RRF，可选窗口重排。 |
| 4 | 按论文轮转编排来源、分配编号，执行上下文与位置同步裁剪。 |
| 5 | 调用实际模型，输出 SSE 增量，审校来源编号及数字断言。 |
| 6 | 对多工具任务校验动作 schema，执行受限并行、错误恢复与终止检查。 |
| 7 | 保存回答、来源、模型与索引快照及已知/未知用量，返回完整或部分结果。 |

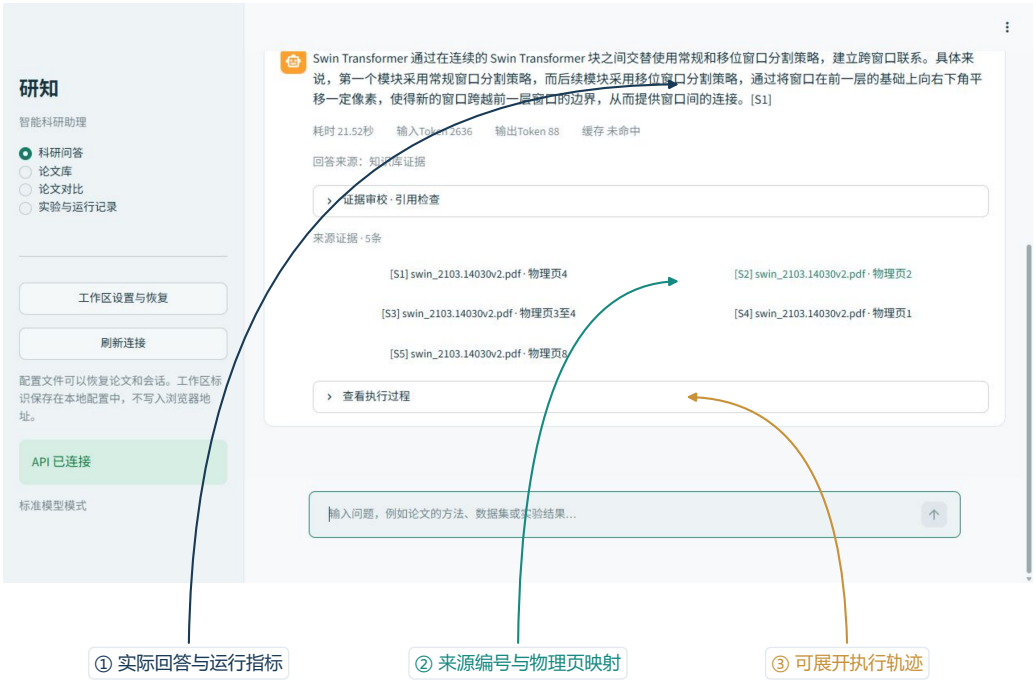
## 4.6 交互实现与功能区说明

界面由科研问答、论文库、论文对比、实验与运行记录四页组成。文档导入呈现批量任务进度和重试，论文库提供元信息编辑、片段与原文查看；问答提供会话、范围、答案、来源和执行轨迹，运行页保留用量与实验配置。以下四张为 2026 年 10 月 10 日留存的真实界面实现截图，按功能区作外部标注，保留原图内容。它们用于说明界面结构，不作为 10 月 15 日新运行问题的回答证据；后者由独立 HTTP 记录和本地就绪截图支持。




2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

**图 2** 论文库的文档管理、索引状态和操作区域。历史真实界面截图，日期为 2026 年 10 月 10 日；标注不改变原图内容。




2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

**图 3** 科研问答的会话与范围、答案和证据区域。截图中的历史回答不是本轮新生成结果，也不代表内容已经通过完整语义评分。




2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

**图 4** 论文对比的文档选择、比较维度与结构化结果区域。实验条件不完整时，界面保留不直接计算差值和排名的限制。

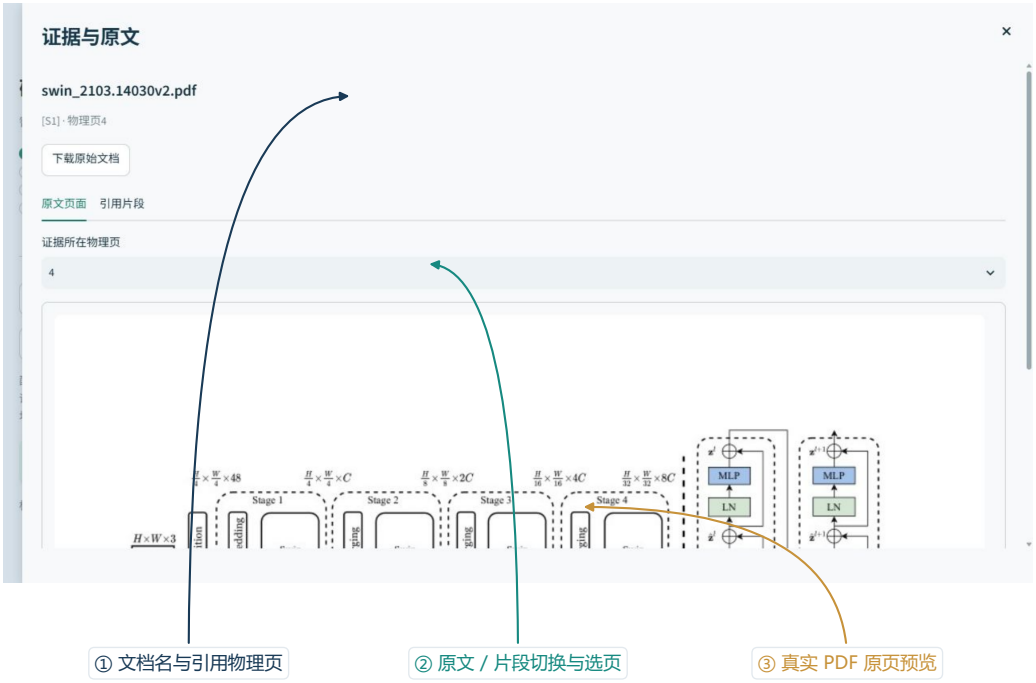



**图 5** 原文证据抽屉的来源、物理页和正文预览区域。页码依据服务器保存的原文元数据，而不是模型自行填写。

## 4.7 评测设计与指标定义

### 4.7.1 语料与题集

选择视觉 Transformer 作为评测方向，收集表9中的 10 篇固定版本论文，涵盖架构、数据效率与训练策略。语料共 169 个物理页，保存原始文件哈希；任务是检索论文信息，不复现论文模型的训练或分类准确率。

参考答案和相关来源由助手依据本地论文逐题核对，相关性采用短文本锚点及物理页、来源段落约束。锚点匹配便于复查，但可能遗漏语义等价证据，也可能把含有短锚点的邻近段落判为相关。题集由开发和资料整理过程接触过的标注构成，因此本文不将测试结果描述为独立多人建立、完全不可见的盲测。

**表 9** 固定版本论文语料及物理页数

| 论文简称 | 固定 arXiv 版本 | 发表信息 | 物理页 |
|---|---|---|---|
| VIT[6] | 2010.11929v2 | ICLR 2021 | 22 |
| DEIT[7] | 2012.12877v2 | ICML 2021 | 22 |
| SWIN[8] | 2103.14030v2 | ICCV 2021 | 14 |
| PVT[9] | 2102.12122v2 | ICCV 2021 | 15 |
| T2T[10] | 2101.11986v3 | ICCV 2021 | 10 |
| CAIT[11] | 2103.17239v2 | ICCV 2021 | 30 |
| CVT[12] | 2103.15808v1 | ICCV 2021 | 10 |
| CROSSVIT[13] | 2103.14899v2 | ICCV 2021 | 12 |
| LEVIT[14] | 2104.01136v2 | ICCV 2021 | 16 |
| BEIT[15] | 2106.08254v2 | ICLR 2022 | 18 |

总计 10 篇、169 个 PDF 物理页。发表年份与 arXiv 首次提交年份分别保留；引用与页码均对应表列固定版本。来源 E01。

**表 10** 题集构成与固定划分

| 题型 | 开发集 | 测试集 | 总计 |
|---|---|---|---|
| 事实型 | 8 | 22 | 30 |
| 比较型 | 4 | 16 | 20 |
| 综合型 | 4 | 11 | 15 |
| 推理型 | 4 | 11 | 15 |
| 合计 | 20 | 60 | 80 |

开发集用于配置探索；全部标签在资料整理阶段已由助手接触，测试集结果不作为独立盲测。来源 E02。

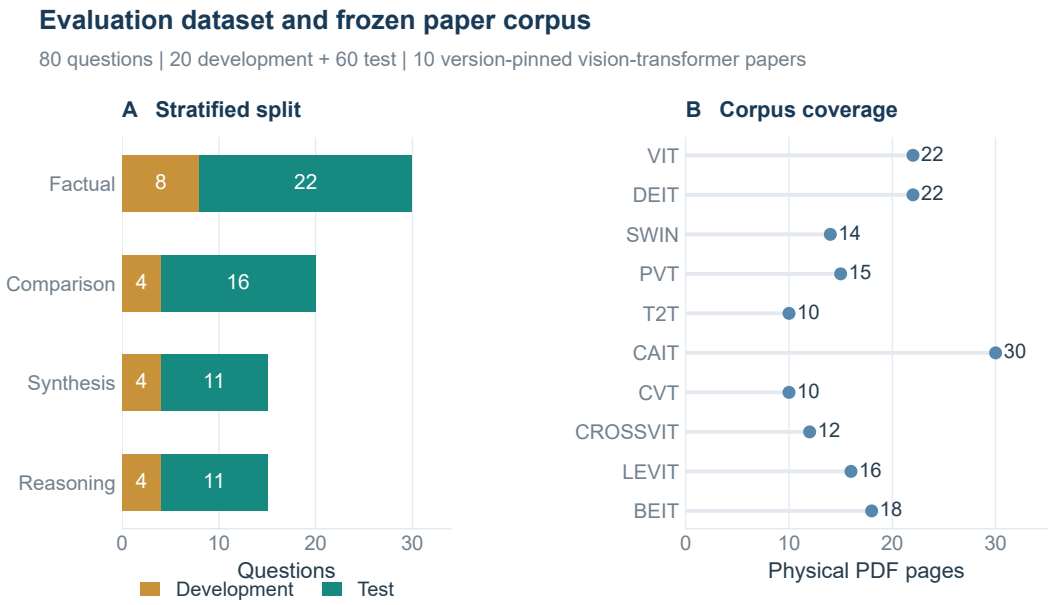



**图 6** 四类问题的开发集和测试集构成。开发集 20 题、测试集 60 题；数量来自固定题集记录。

### 4.7.2 指标与比较条件

设第 $i$ 题的标注来源证据单元集合为 $G_i$，前 $K$ 条检索结果覆盖的来源证据单元集合为 $R_i^{(K)}$，首个相关项名次为 $r_i$。本项目报告

$$\mathrm{Hit@K} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}[R_i^{(K)} \cap G_i \neq \varnothing], \tag{7}$$

$$\mathrm{Recall@K} = \frac{1}{n}\sum_{i=1}^{n} \frac{|R_i^{(K)} \cap G_i|}{|G_i|}, \tag{8}$$

$$\mathrm{MRR} = \frac{1}{n}\sum_{i=1}^{n} \frac{\mathbb{I}[r_i < \infty]}{r_i}. \tag{9}$$

实际相关项匹配遵循源记录中的文档、物理页及锚点规则；MRR 使用实验候选深度内首个相关项，而不是自动视为 MRR@5。路由 exact-match 只比较预期工具集合与实际工具选择；用量与延迟分别保存已知 token、估算标记和时间范围。质量评分采用正确性、完整性、引用支撑与流畅性四维 1—5 分量表。

正式三档检索和短答案生成使用历史 359 片段索引；分

块/Embedding 比较中的递归索引与 10 篇生产语料为 342 片段；本轮本地运行验收为独立 CvT 工作区 29 片段。这些版本不能合并为一次统一端到端实验。三档检索复用已真实编码的查询向量，生成研究复用真实命中，不能用其计时替代在线完整路径。

## 4.8 解析分块模型与向量库实验

**表 11** 三种 PDF 解析器的实测结果

| 解析器 | 累计耗时/s | 锚点保持 | 表格块 | 公式块 |
|---|---|---|---|---|
| pymupdf | 38.565 | 119/119 | 157 | 119 |
| pdfplumber | 29.251 | 119/119 | 141 | 231 |
| pypdf2 | 9.124 | 114/119 | 0 | 1 |

每个解析器处理相同 10 篇论文；锚点保持率是代理指标，不代表完整版面、表格或公式识别准确率。来源 E03。

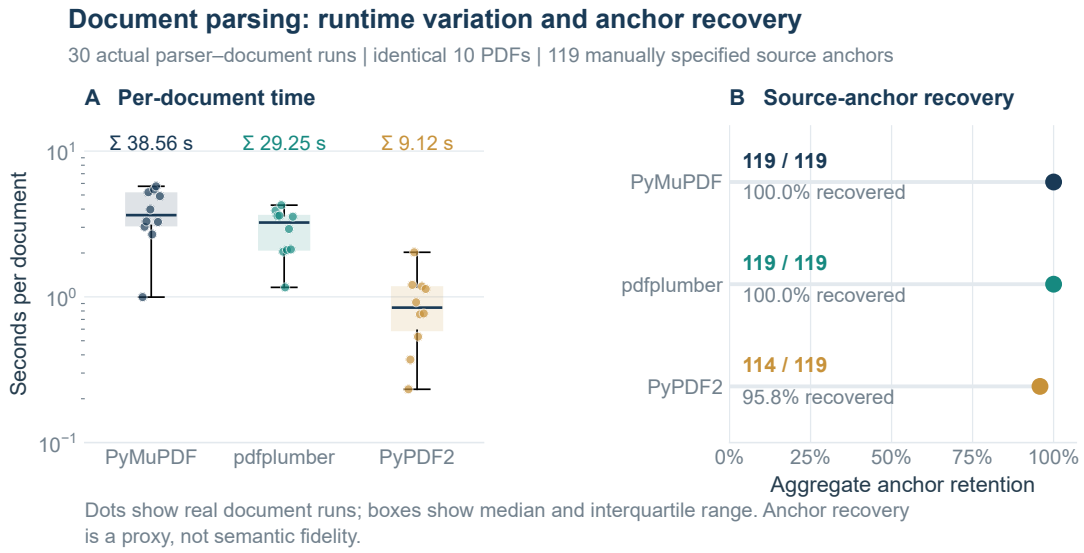



**图 7** 相同 10 篇论文上的解析累计耗时和 119 个来源锚点保持率。检测块数与锚点保持均不是完整语义识别率。来源 E03。

PyPDF2 的累计耗时较低，但锚点保持为 114/119，且缺少块级坐标；其表格和公式块检测数量不能与布局解析器简单等价。PyMuPDF 与 pdfplumber 均保留全部既定锚点，也不能由此推断所有阅读顺序、表格或公式均正确。

**表 12** 同一 m3e 模型下的五种分块配置比较

| 分块配置 | 片段数 | Hit@5 | MRR | Recall@5 |
|---|---|---|---|---|
| fixed-256 | 724 | 0.3500 | 0.2921 | 0.3250 |
| fixed-512 | 314 | 0.4000 | 0.2699 | 0.3750 |
| fixed-1024 | 150 | **0.5000** | **0.3604** | **0.4000** |
| recursive-512 | 342 | 0.4000 | 0.2785 | 0.3500 |
| semantic-512 | 326 | 0.4500 | 0.3078 | **0.4000** |

开发集 20 题；混合检索（Dense、BM25 与 RRF），每种切分使用其实际索引。分块单位为项目定义的轻量 token，不等同于模型 tokenizer。来源 E04。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

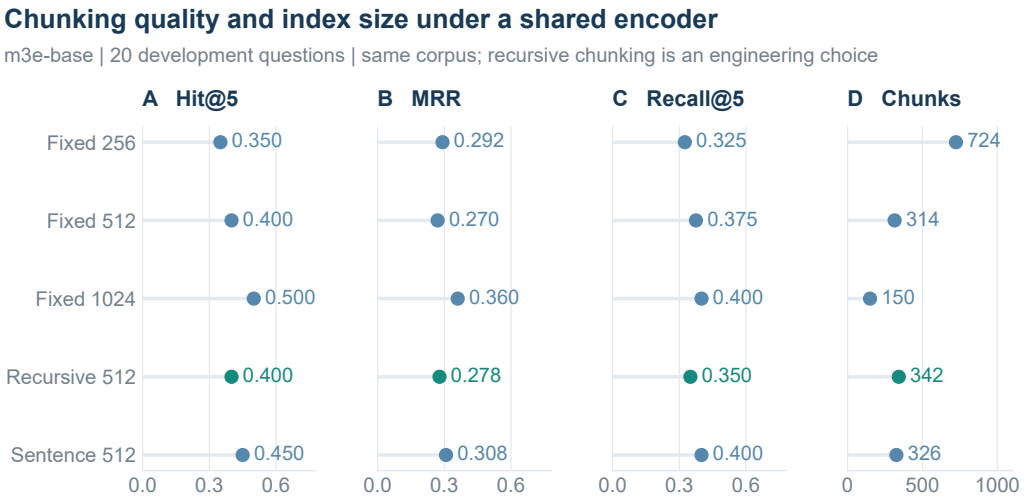



**图 8** 同一 m3e 模型和 20 题开发集上的分块配置比较。每个切分方案具有自己的真实片段索引。来源 E04。

固定 1024 在该开发集的 Hit@5 和 MRR 最高，递归 512 没有取得最高指标。生产选择递归策略是来源结构、上下文预算与工程一致性的折中，不以实验数据未支持的“最优切分”解释。长块可能增加包含相关锚点的机会，也可能稀释局部语义，因此需在更多题目与上下文预算下重复比较。

**表 13** Embedding 模型质量与查询编码代价

| 模型 | 维度 | Hit@5 | MRR | Recall@5 | 编码/ms |
|---|---|---|---|---|---|
| m3e-base | 768 | **0.4000** | 0.2785 | **0.3500** | 43.94 |
| bge-large-zh-v1.5 | 1024 | 0.3500 | **0.2960** | 0.3000 | 212.43 |

同 342 片段、开发集 20 题、递归 512 配置。最后一列为 20 个实际查询的编码总时间除以 20，不包含模型加载，亦不是逐请求在线延迟。此表没有比较 BGE-M3。来源 E05。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

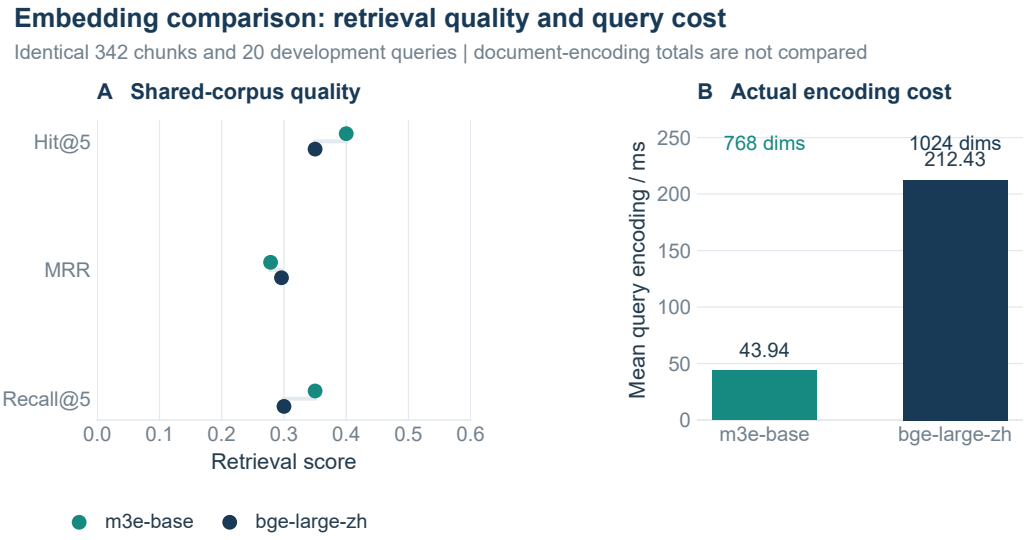



**图 9** 一致递归索引下的模型质量与 20 题查询编码摊销时间。m3e 和 BGE-large-zh 的 MRR 及 Hit@5 各有差异，不能单一排序为全面优劣。来源 E05。

m3e 的 Hit@5 为 0.4000，高于 BGE-large-zh 的 0.3500；后者 MRR 较高，说明命中与排序指标需要分别解释。文档编码吞吐统计的文本集合不同：m3e 覆盖五种切分去重后的 1836 条，BGE-large 为递归方案 342 条，因而不作同分布吞吐结论。

两个后端得到相同的检索质量，但持久化构建和查询耗时不同。这些结果主要用于验证后端可替换性和本机行为，不足以推断大规

**表 14** 相同真实向量下的存储后端比较

| 后端 | 构建/ms | 查询均时/ms | Hit@5 | MRR | Recall@5 |
|---|---|---|---|---|---|
| chroma | 1165.03 | 2.291 | **0.3500** | **0.3236** | **0.2750** |
| faiss | 156.44 | 6.246 | **0.3500** | **0.3236** | **0.2750** |

历史 359 片段、1024 维真实向量及同 20 个开发集查询；查询时间排除共享编码。删除与恢复探针均通过。规模有限，不能据此证明后端普遍优劣。来源 E06。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

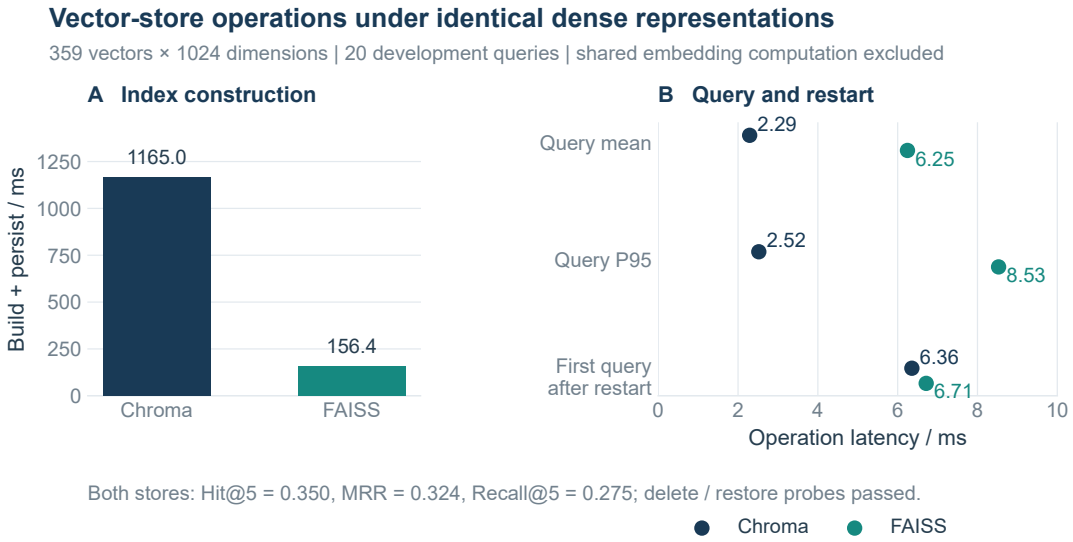



**图 10** 同一 359 片段与真实向量的后端质量和查询耗时。后端比较复用模型推理，结果仅代表当前规模与实现。来源 E06。

模吞吐、召回近似误差或生产集群优势。

## 4.9 三档检索消融与参数迭代

**表 15** 冻结测试集上的三档检索结果

| 模式 | Hit@5 | MRR | Recall@5 | 均时/ms | P95/ms |
|---|---|---|---|---|---|
| 向量 | 0.4167 | 0.2992 | 0.3250 | 3.20 | 4.03 |
| 混合 RRF | 0.4333 | 0.3538 | 0.3583 | 8.27 | 10.31 |
| 混合加重排 | **0.6167** | **0.4313** | **0.4750** | 16708.41 | 18625.26 |

每模式 60 题，历史 359 片段；各模式执行错误数均为 0。预计算查询编码不包含在排序耗时内；BGE-M3 全部 80 题查询编码均摊为 112.915 ms/题。来源 E07。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

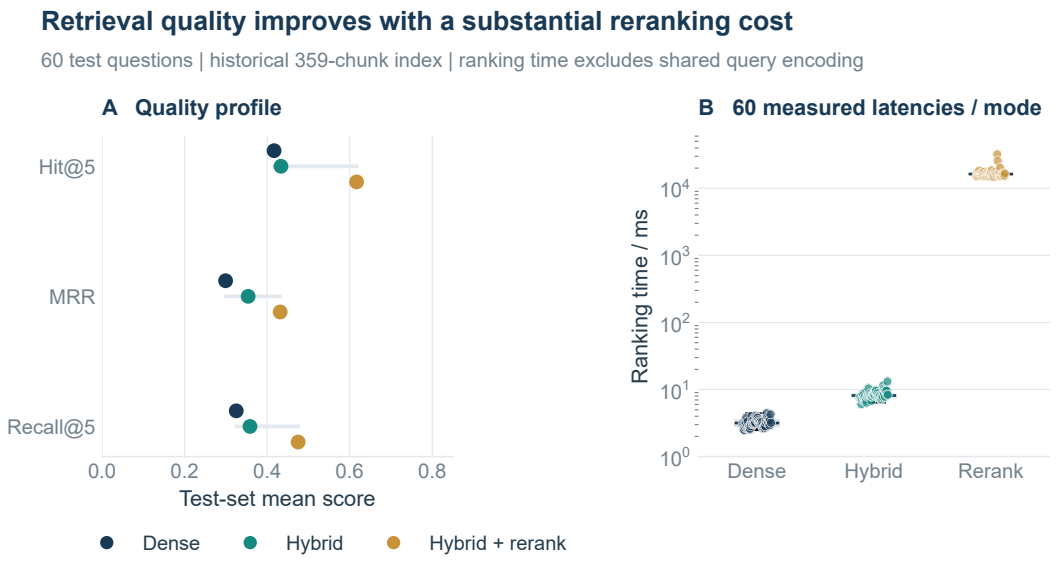



**图 11** 同一历史 359 片段与 60 题测试集上的检索模式消融。重排提高证据覆盖，同时引入 CPU 推理成本。来源 E07。

混合加重排的 Hit@5 较纯向量提高 20.00 个百分点，较混合 RRF 提高 18.33 个百分点，Recall@5 也提高。但其 CPU 排序均时约 16.7 秒，显著高于预编码向量的纯检索阶段；不能将纯向量 3.20 ms 写成在线问答时延。误差区间采用对实际题目进行 5000 次 percentile bootstrap、固定随机种子 20261015。图12表示题目抽样不确定性，不是模型多次运行方差，也不据此宣称统计显著。 图13进一步使用同

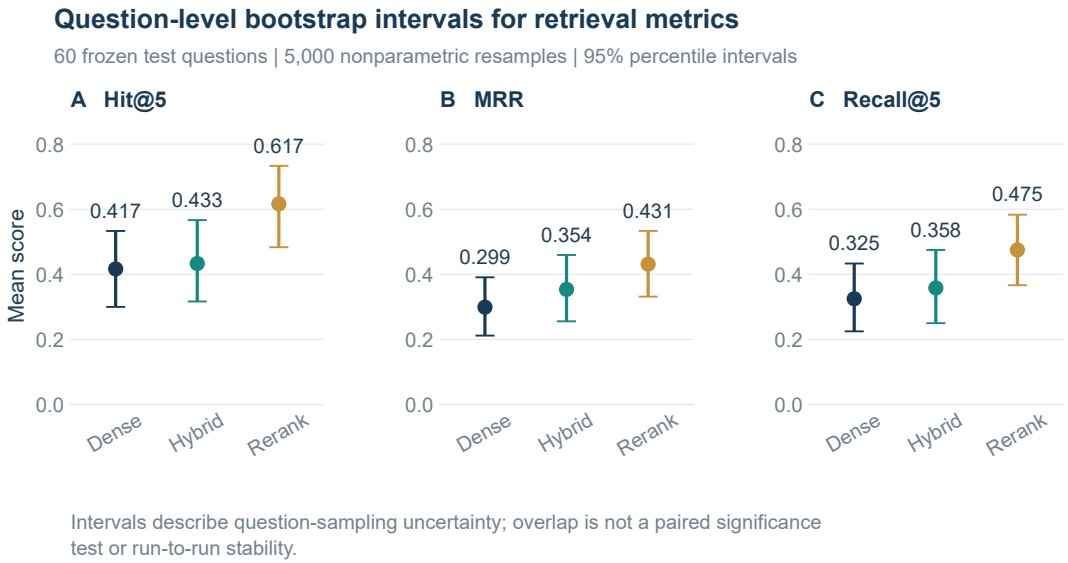



**图 12** 60 题逐题重采样的 95% percentile 区间。每个模式使用同样的实际问题集合；区间不替代重复运行或配对显著性检验。来源 E07。

**表 16** 同题配对的检索效果差及其题目级区间

| 比较（后者减前者） | 指标/单位 | Δ | 95% 区间 |
|---|---|---|---|
| 向量 → 混合 | Hit@5/百分点 | +1.67 | [-8.33, 13.33] |
| 向量 → 混合 | MRR/原量纲 | +0.0546 | [-0.0008, 0.1139] |
| 向量 → 混合 | Recall@5/百分点 | +3.33 | [-5.00, 12.50] |
| 混合 → 混合 + 重排 | Hit@5/百分点 | +18.33 | [8.33, 30.00] |
| 混合 → 混合 + 重排 | MRR/原量纲 | +0.0775 | [-0.0231, 0.1770] |
| 混合 → 混合 + 重排 | Recall@5/百分点 | +11.67 | [3.33, 20.00] |
| 向量 → 混合 + 重排 | Hit@5/百分点 | +20.00 | [10.00, 31.67] |
| 向量 → 混合 + 重排 | MRR/原量纲 | +0.1322 | [0.0428, 0.2266] |
| 向量 → 混合 + 重排 | Recall@5/百分点 | +15.00 | [5.83, 25.00] |

各比较使用同 60 题；同次抽样索引应用于全部模式。10000 次 percentile 重采样，seed=20261017。混合指 RRF 融合；Hit 与 Recall 列按百分点换算，MRR 不换算。区间仅刻画题目构成不确定性，不作显著性检验。来源 E07 及派生统计快照。

一题目的模式差值，三组比较的每次重采样均保留题目配对关系。差值及其 95% 区间用于描述本题集上的效果与题目构成不确定性，不作显著性判定。

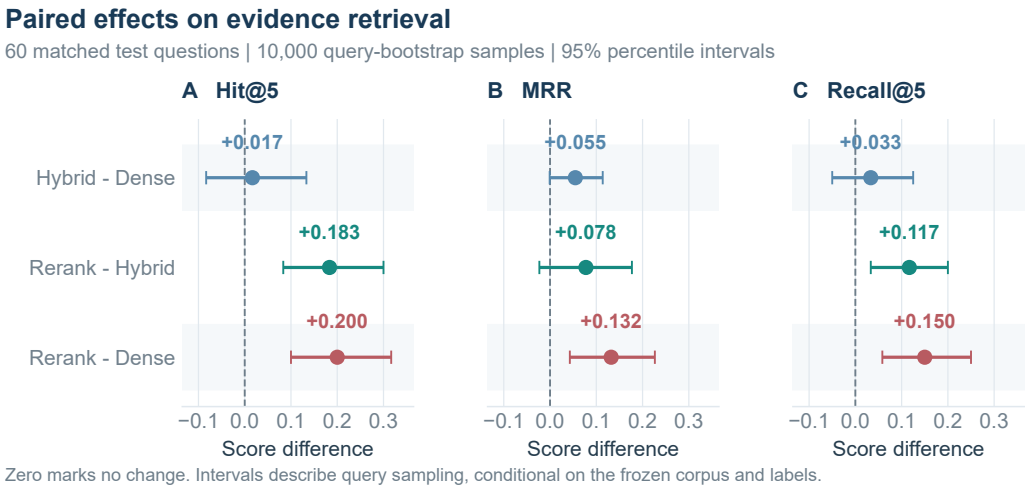



**图 13** 三组检索模式比较的配对效果。横轴为后者减前者的指标差，线段为题目级配对 bootstrap 的 95% 区间。图中均采用 0—1 指标的原量纲差值；Hit 与 Recall 在表16换算为百分点，MRR 不换算。来源 E07 及派生统计快照。

**表 17** 开发集 RRF 常数与截断深度比较

| RRF 常数 | 评价 K | Hit@K | Recall@K | MRR@20 |
|---|---|---|---|---|
| 20 | 3 | 0.4000 | 0.3500 | 0.324717 |
| 20 | 5 | 0.4000 | 0.3500 | 0.324717 |
| 20 | 10 | 0.6500 | 0.5750 | 0.324717 |
| 60 | 3 | 0.4000 | 0.3500 | 0.314796 |
| 60 | 5 | 0.4000 | 0.3500 | 0.314796 |
| 60 | 10 | 0.6500 | 0.5750 | 0.314796 |
| 100 | 3 | 0.4000 | 0.3500 | 0.314796 |
| 100 | 5 | 0.4000 | 0.3500 | 0.314796 |
| 100 | 10 | 0.6500 | 0.5750 | 0.314796 |

同 20 个开发集问题，复用实际编码和检索排名，无新增模型调用。MRR 固定在候选深度 20 定义，不随评价 K 重新计算。来源 E08。

RRF 常数 60 改为 20 后，MRR@20 由 0.314796 变为 0.324717，而 Hit@5 为 0.40、Recall@5 为 0.35，均未变化。该轮实际优化改善

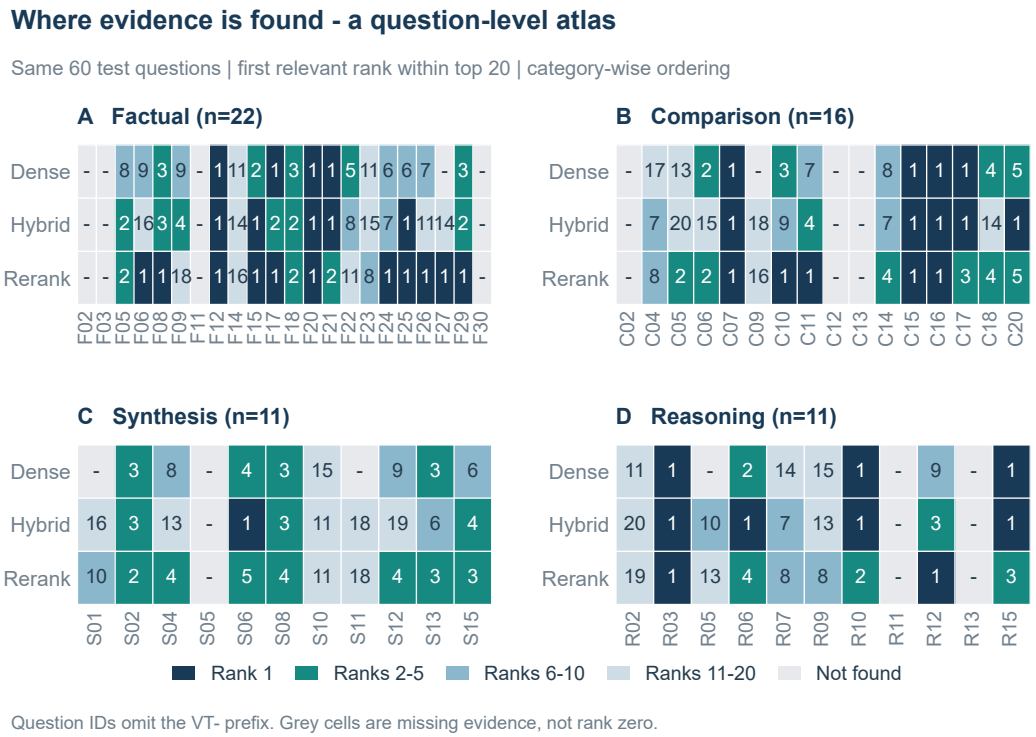



**图 14** 同 60 题在三种检索模式下的逐题首个相关项名次。题目按四类任务分组，颜色仅对应已检到项；null 表示在保存的候选深度内未检到，不能填充为末位名次。来源 E07。

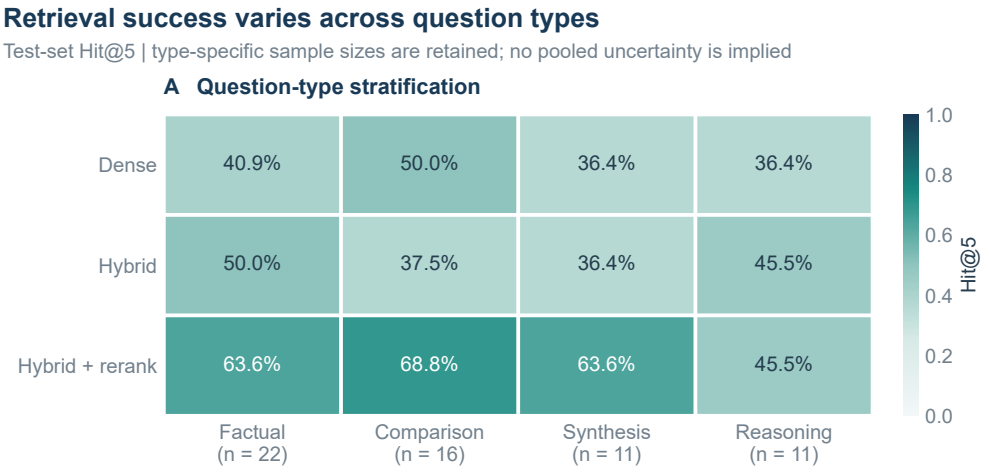



**图 15** 按事实、比较、综合和推理问题分解的 Hit@5。各类样本量不同；推理题在重排后仍保留较大漏召回空间。来源 E07。

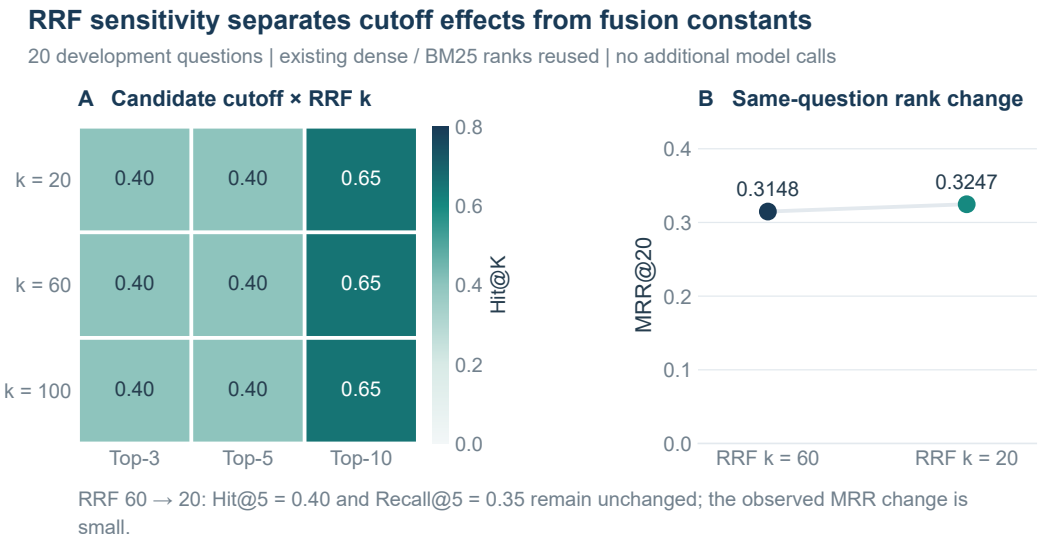



**图 16** RRF 常数与评价截断深度的开发集网格。图中分别呈现 Hit@K 与 MRR@20；后者按候选深度 20 计算，不随评价 K 重新定义。来源 E08。

了排名，未解决前五条的漏召回；本文保留这一有限改善而不使用“召回显著提高”的表述。

## 4.10 答案质量生成参数与提示词比较

**表 18** 60 条实际短答案的质量评审

| 维度 | 均分/5 | 1 分 | 2 分 | 3 分 | 4 分 | 5 分 |
|---|---|---|---|---|---|---|
| 正确性 | 3.50 | 5 | 11 | 13 | 11 | 20 |
| 完整性 | 2.98 | 4 | 21 | 14 | 14 | 7 |
| 引用支撑 | 3.03 | 12 | 13 | 13 | 5 | 17 |
| 流畅性 | 4.58 | 0 | 1 | 5 | 12 | 42 |

每维 60 条，评分日期 2026 年 10 月 14 日；独立人工评分为 0。1—5 分是有序量表，不是答案准确率，也不是教师课程总分。来源 E09。

四维均分分别为 3.50、2.98、3.03 和 4.58。该分布说明语言流畅不能替代证据覆盖、数值正确及来源支持。评分基于原回答、参考答案、实际引用映射和论文物理页，保留逐题评语。

参数实验合计 20 条真实回答，提示词实验含旧模板 4 条及复用基线的当前模板 4 条。28 个条件记录对应 24 次历史调用，按问题、

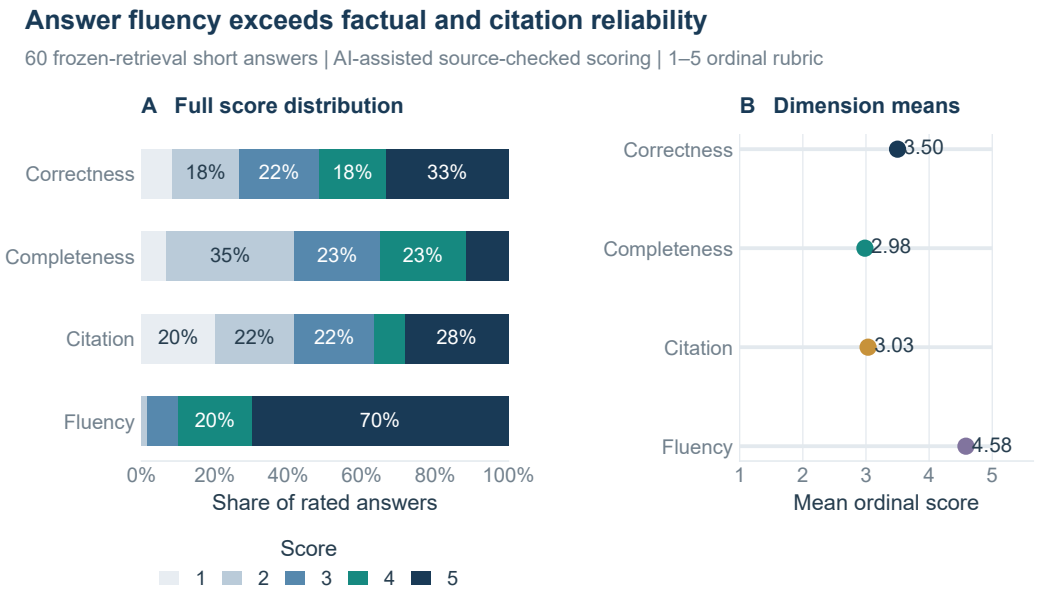



**图 17** 60 条历史短答案的量表评审。流畅性明显高于完整性与引用支撑。来源 E09。

**表 19** 四类题目的分维度均分

| 题型 | $n$ | 正确性 | 完整性 | 引用支撑 | 流畅性 |
|---|---|---|---|---|---|
| 事实型 | 22 | 3.91 | 3.41 | 3.45 | 4.73 |
| 比较型 | 16 | 3.06 | 2.62 | 2.69 | 4.56 |
| 综合型 | 11 | 3.27 | 2.27 | 3.36 | 4.36 |
| 推理型 | 11 | 3.55 | 3.36 | 2.36 | 4.55 |

均分范围 1—5，按题目等权计算；四类样本数合计 60。不同题型并非同难度配对任务，不据均分差异推断题型的固有难度。评分来源与表18一致。来源 E09 及派生统计快照。

**表 20** 生成参数的质量与成本对比

| $T/p/k_s$ | 正确 | 完整 | 引用 | 流畅 | 生成/s | 输出/条 |
|---|---|---|---|---|---|---|
| 0.1/0.9/40 | **4.25** | **4.00** | **3.50** | **5.00** | 3.255 | 84.25 |
| 0.0/0.9/40 | 3.75 | 3.75 | **3.50** | 4.75 | 2.503 | 115.00 |
| 0.5/0.9/40 | 3.75 | 3.50 | 3.25 | **5.00** | 1.415 | 59.50 |
| 0.1/0.7/40 | 3.75 | 3.50 | 3.25 | **5.00** | 1.705 | 73.25 |
| 0.1/0.9/20 | **4.25** | **4.00** | **3.50** | **5.00** | 1.885 | 84.25 |

各条件仅 4 道开发集题，每题单次生成；输出上限 256 token。$k_s$ 为采样 Top-k，与检索返回 Top-K 不同。质量来源为 AI 评审。来源 E10。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

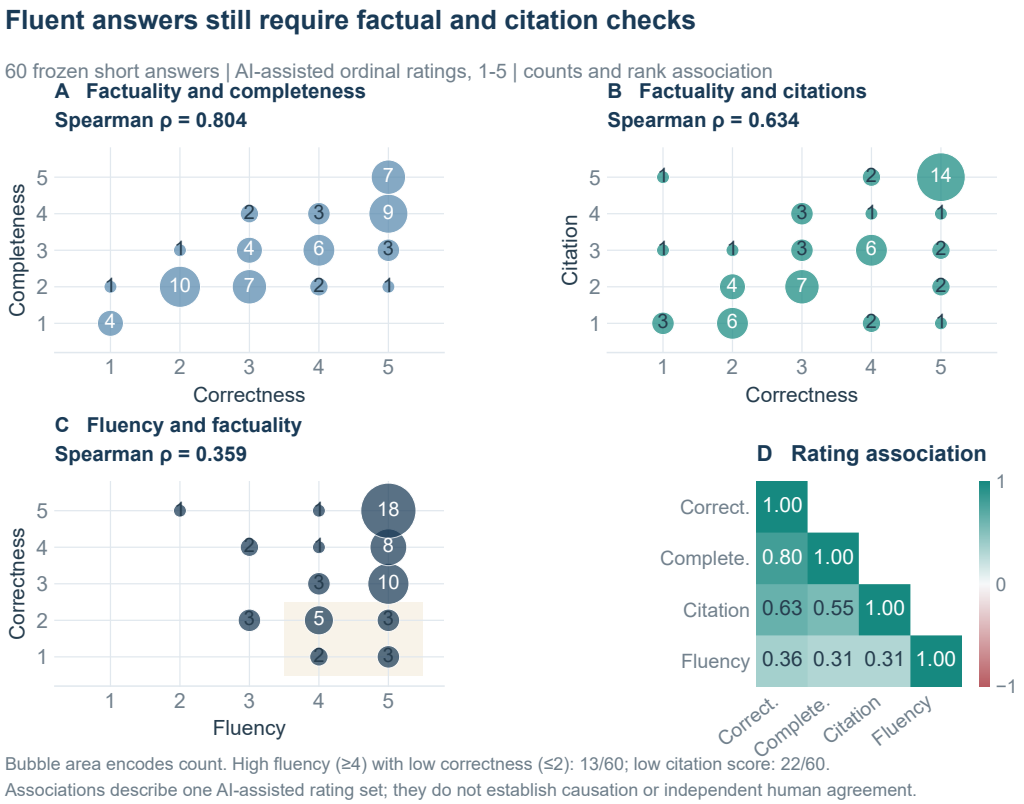



**图 18** 评分的联合分布与秩相关。气泡依次表示正确性—完整性、正确性—引用支撑、流畅性—正确性的评分组合，面积为题数；热图为 Spearman 相关。其共同变化不证明因果联系或人工评分一致性。来源 E09 及派生统计快照。

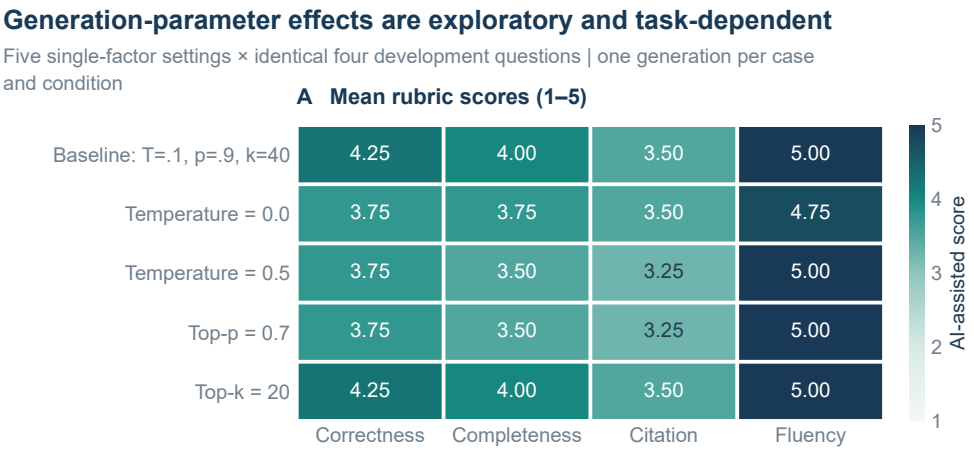



**图 19** 生成参数条件的四维评分。每条件 4 题，包含事实、比较、综合和推理；相同输出复用同一评分。来源 E10。

原回答和引用映射去重后有 17 个独立答案。基线与采样 Top-k 为 20 的条件均值并列，但逐题错误构成不同，不能据此宣布某组参数稳定最优。温度为 0 未消除综合题中的事实错误；较短回答的生成耗时较低，同时受输出长度、模型热身和条件执行顺序混杂。

**表 21** 提示词对照的分维度结果

| 模板 | 正确性 | 完整性 | 引用支撑 | 流畅性 | 生成/s |
|---|---|---|---|---|---|
| 简化对照 | **4.25** | 3.75 | 2.50 | **5.00** | 3.551 |
| 当前证据约束 | **4.25** | **4.00** | **3.50** | **5.00** | 3.255 |

每模板 4 条；当前模板复用参数基线回答，不是额外 4 次生成。新旧实验合计 28 个条件记录、24 次历史生成调用、17 个独立答案评审。来源 E10。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

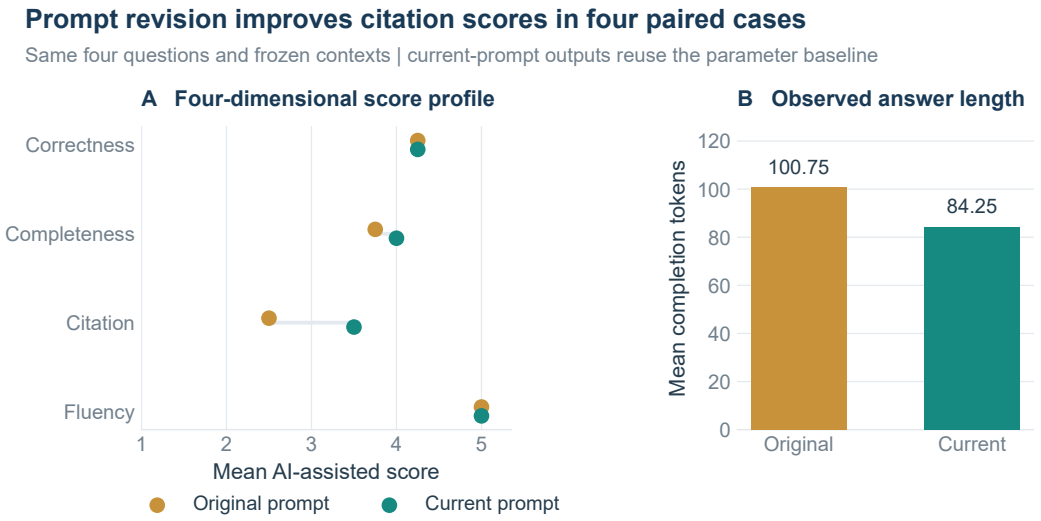



**图 20** 简化对照与当前证据约束提示词的比较。正确性均值不变，完整性增加 0.25、引用支撑增加 1.00 分；样本不足以支持普遍优势。来源 E10。

事实题中，旧回答正确给出 ViT-Base 配置，但引用位置与其自写页码不符；当前回答采用实际包含表 1 的来源，改善了引用支撑。另一方面，综合题的冻结 Top5 均来自 T2T，没有 CvT 原文，多个配置仍将普通 ViT 机制错误归给 CvT。该例表明，采样和提示词不能独立修复证据覆盖缺失，应在生成前检验所需论文是否均有可靠来源。

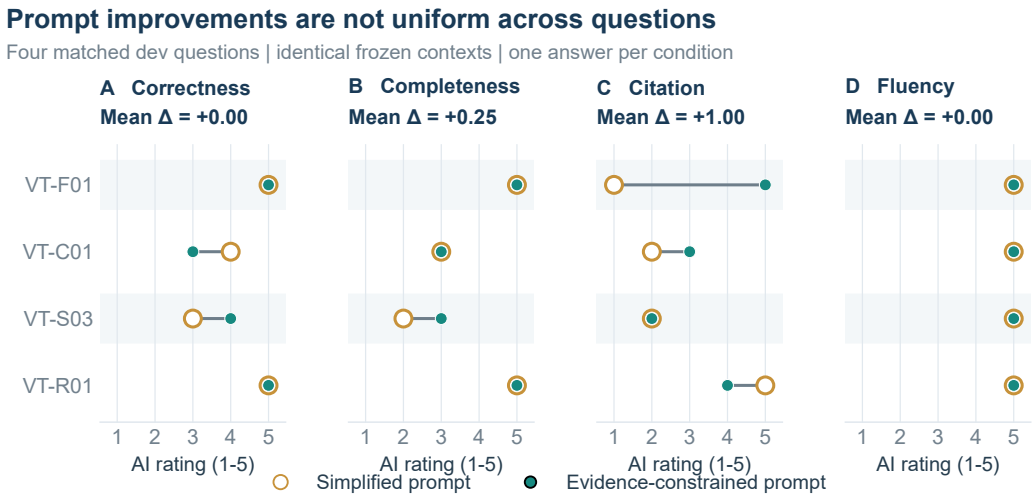



**图 21** 四题提示词比较的逐题配对分数。连接线对应同一题目，保留改善、持平与退化的实际结果；每题每模板单次生成，不由四题观测推断总体效果。来源 E10 及派生统计快照。

## 4.11 Agent 效率与本地运行验收

**表 22** 固定 RAG 与 Agent 探针的实际资源记录

| 路径 | 次数 | 均时/s | P95/s | 输入合计 | 输出合计 |
|---|---|---|---|---|---|
| 固定 RAG | 5 | 1.254 | 1.958 | 18105 | 250 |
| Agent | 5 | 2.481 | 4.648 | 10109 | 469 |

同 5 个探针、每路径 5 次；Agent 路由 exact-match 为 1.00，仅说明给定探针的工具选择，不等于答案正确率。计时为冻结检索后的生成与工具流程。来源 E11。

固定 RAG 与 Agent 各运行 5 次，Agent 输入 token 合计较少而均时较高，说明减少输入并不保证端到端更快。概念、计算、时间、关键词和论文事实五类探针只覆盖部分路由，不能据此给出全任务成功率。 串行与双线程工具均时为 24.125 与 21.161 ms，未包含 LLM 并发；缓存冷请求 2955.515 ms，精确重复 4.074 ms，后者新增模型 token 为 0。缓存样例说明功能生效，不作为总体命中率或稳定数百倍加速证据。另有 10 次异质在线诊断请求，平均端到端 52.089 秒，输入/输出合计 43908/4634 token，平均 Agent 步数 1.2；任务不同，不构成同题受控负载测试。

本地标准模式实际访问前端 8501、API 8000 和项目模型服务

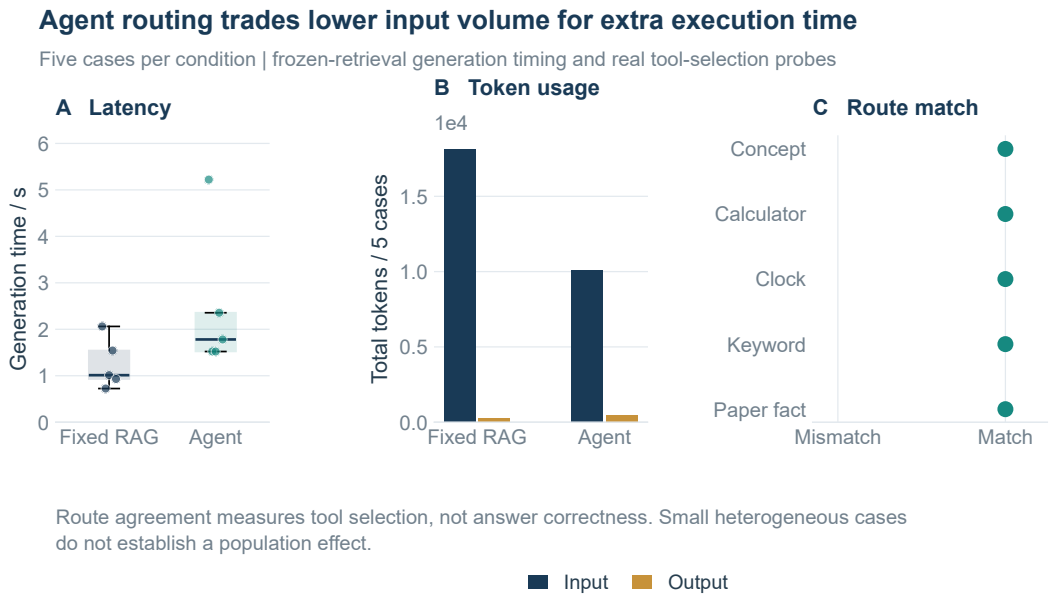



**图 22** 5 个探针上固定 RAG 与 Agent 的时延和 token 结构。路由匹配为 1.00，不是答案正确率；不同路径的开销组成应分别解释。来源 E11。

**表 23** 本地工具并行与缓存功能探针

| 条件 | 次数 | 均时/ms | 输入 token | 输出 token |
|---|---|---|---|---|
| 串行本地工具 | 10 | 24.125 | 0 | 0 |
| 双线程本地工具 | 10 | 21.161 | 0 | 0 |
| 缓存冷请求 | 1 | 2955.515 | 3599 | 54 |
| 精确重复命中 | 1 | 4.074 | 0 | 0 |

并行探针不调用 LLM；缓存每条件仅 1 次，不能外推语义近邻命中率或稳定加速倍数。来源 E12。

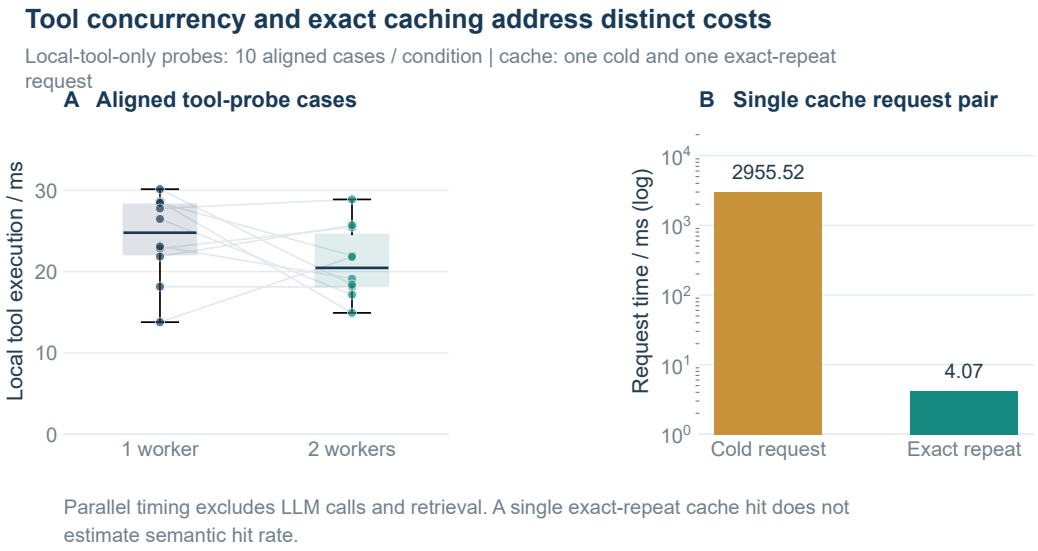



**图 23** 本地独立工具的串行/双线程配对记录与精确重复缓存探针。缓存使用对数耗时坐标；样本量分别为 10 轮/方式和 1 次/条件。来源 E12。

**表 24** 2026 年 10 月 15 日本地独立流程验收

| 项目 | 实际记录 |
|---|---|
| 文档与片段 | CvT 原文 PDF，独立工作区 29 片段 |
| 模型与来源 | research-qwen:7b；knowledge_rag |
| 运行状态 | 33 类检查通过；0 失败 |
| 候选与结果 | 候选 20 条，返回 5 条 |
| 端到端问答 | 34.15 s |
| 检索与重排 | 19.28 s |
| 首个 token | 26.04 s |
| 实际输入/输出 | 3537 / 395 token |
| 自动审校 | |

正式操作时间为北京时间 17:21:16—17:23:24；33 类检查对应 120 条含轮询的断言记录。这里只验收一次真实流程，不作为完整题集成绩或稳定时延。来源 E14。

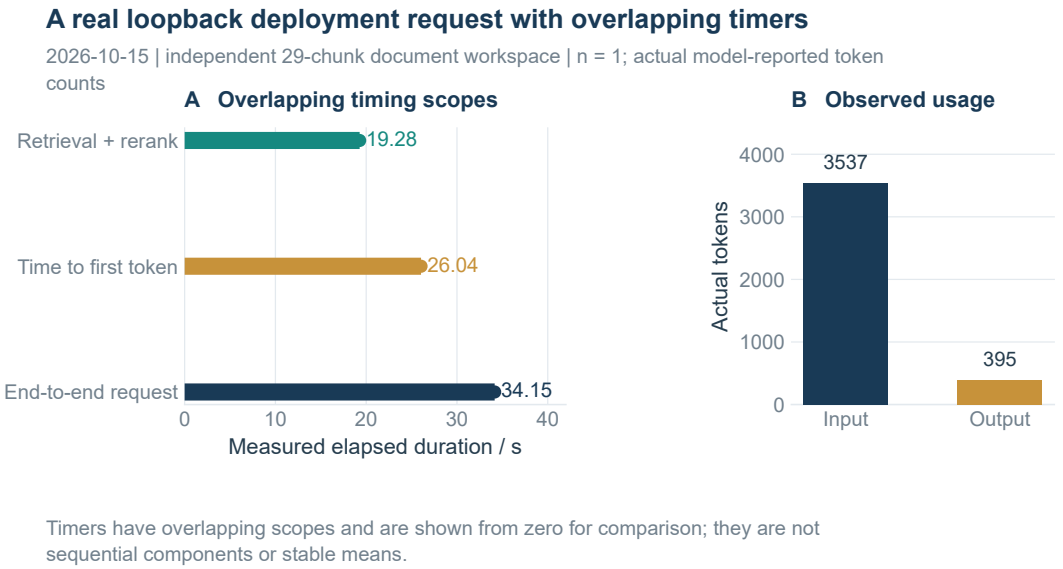



**图 24** 独立 CvT 本地验收的单次问答资源记录。端到端、检索和首 token 计时互有包含，不能相加；该样例不代表完整题集均值。来源 E14。

11435，均绑定 127.0.0.1，保留原系统 11434 服务。验收核对了真实 PDF 上传、29 片段索引、模型 SSE 回答、有效来源编号、原件 SHA-256、引用页 PNG 及会话和调用保存。33 类检查均通过，轮询计入时共有 120 条通过断言；不能把它们写成 120 项独立功能。本次回答仍有 5 条自动审校待核查提示，所以运行通过不表示全部语义正确。

## 4.12 Bad Case 分析与优化边界

实际问题还包括 Swin 型号与数值错配、PVT 下采样解释、LeViT 结构与 class token 判断、算术错误以及训练条件归属颠倒。这些问题不能仅依靠界面完善或降低温度消除，应优先核验引用覆盖、数值计算来源和跨论文实验条件。除 RRF 同题优化外，结构化比较、服务端页码校正和窗口修复有定向回归或真实样例记录；样例关注点不完全一致时，只作诊断证据而不据其计算因果提升。




**图 25** 2026 年 10 月 15 日本地页面与模型就绪状态截图。截图仅证明页面加载状态；当日实际新问答以 E14 中的 HTTP、SSE 和调用记录为准。

**表 25** 四类 Bad Case 与工程输入窗口问题

| 类型 | 观察与根因 | 改进及剩余限制 |
|---|---|---|
| 检索失败 | 相近架构文本干扰，跨语言实体与跨论文覆盖不足 | 混合检索和配置探索；RRF 改进只改善 MRR，仍有漏召回 |
| 生成错误 | 自由格式输出、模型补写数值及事实归属错误 | schema 与有界修复；格式可用仍不等于语义正确 |
| 引用错误 | 模型自写页码，来源编号与事实对应不严 | 服务器页码和来源核对；断言语义支持仍需复查 |
| Agent 决策 | 规划阶段编造文档标识或重复动作 | 固定明确文档范围、重复与预算终止；探针规模有限 |
| 超长窗口 | decode/re-encode 导致长度膨胀与输入拒绝 | 原 token-ID 全覆盖分窗；不宣称等价于无限上下文编码 |

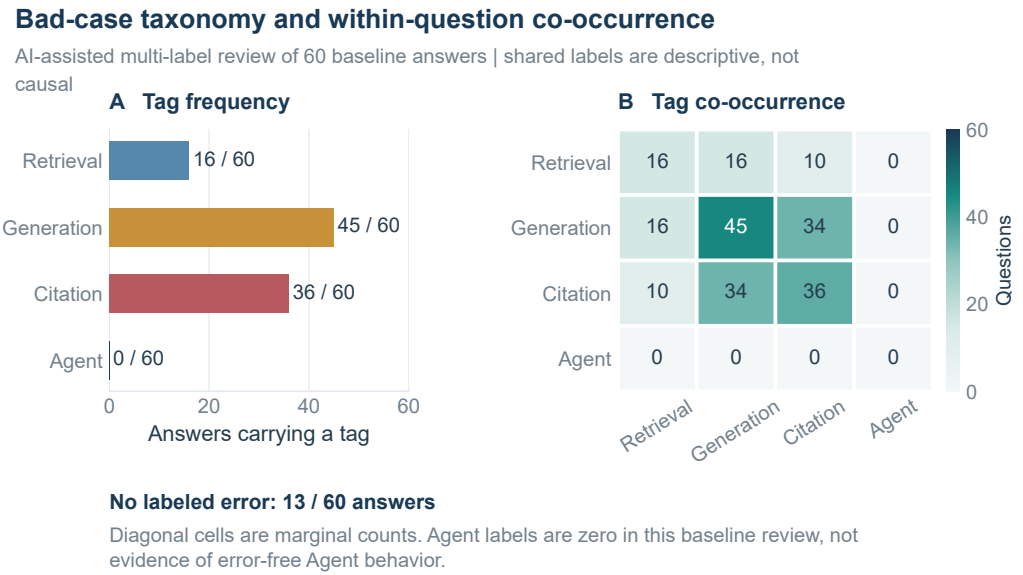



**图 26** 60 条评分记录的多标签错误分布。同一回答可同时计入检索、生成和引用错误，因此总数可超过 60；“无明显问题”不等于全面语义认证。来源 E09、E15。

# 五 技术设计文档

## 5.1 模块接口与持久化

API 封装文档、任务、会话、运行和实验操作。文档任务状态包括 queued、running、done 与 error；文档就绪后才能进入限定范围的检索。回答、来源、执行事件与配置快照在同一运行记录中保存，便于从界面回到实际调用。部分核心接口见表26，精确 schema 以项目实际 API 文档为准。

## 5.2 配置与可复现控制

配置由 YAML 和环境变量合并，公开配置排除云端 API 密钥。应用默认上下文、输出、检索和 Agent 预算见表27；不同实验覆盖的值写入各自记录，不从当前默认值倒推历史配置。

**表 26** 核心接口及数据用途

| 方法 | 路径 | 作用 |
|---|---|---|
| GET | /health | 存活、模型及检索就绪 |
| GET | /config | 不含 API 密钥的公开配置 |
| POST | /documents | 批量上传及异步索引任务 |
| GET | /jobs/<id> | 索引进度和实际错误 |
| GET | /documents/<id>/chunks | 分页片段及位置 |
| GET | /documents/<id>/preview | 论文物理页预览 |
| POST | /sessions/<id>/chat | SSE 问答与来源事件 |
| GET | /runs/<id> | 回答、用量及执行追踪 |
| GET | /sessions/<id>/export | 会话导出 |

**表 27** 主要配置与实验覆盖关系

| 配置项 | 取值 | 含义与范围 |
|---|---|---|
| chunk_size/overlap | 512/64 | 轻量分块单位；实验另有 256、1024 |
| candidate_k/result_k | 20/5 | 检索候选与最终来源数量 |
| rrf_k | 60 | 历史基线；开发集另比较 20、100 |
| context_tokens | 4096 | 上下文预算配置，采用保守估算 |
| answer_tokens | 768 | 生产上限；生成研究为 256 |
| temperature/top_p | 0.1/0.9 | 历史基线与实际条件分别记录 |
| top_k_sampling | 40 | 采样参数，不是检索 Top-K |
| max_agent_steps | 6 | 循环预算 |
| memory_tokens | 1400 | 历史记忆估算预算 |
| memory_recent_messages | 8 | 近期窗口上限 |
| cache_threshold | 0.96 | 还需满足锚点、历史与指纹条件 |

### 5.3 隔离错误与安全边界

服务端对文档、会话、运行和实验读取进行工作区归属校验；随机标识提供本地逻辑隔离，不等于完整生产身份认证。上传检查扩展名、空文件及大小，去除文件名路径部分，默认单文件 50 MB、单批 20 份。安全计算器使用白名单 AST；论文正文和工具结果作为数据处理，不赋予其覆盖系统规则的权限。未获得的失败调用用量保留未知，不填零。模型、工具或索引失败通过明确状态、警告及可检查的部分结果呈现。本次部署采用回环地址，不据此推断互联网访问环境下的安全性或并发能力。

### 5.4 扩展设计的价值与限制

第一项扩展是版本感知的来源与运行记录：编码窗口版本、模型 revision、语料哈希、索引快照与生成配置共同记录，用于识别缓存和实验是否可比。其价值是降低跨版本误用风险，不是对所有历史执行的第三方审计认证。第二项扩展是条件约束的结构化论文比较：对明确论文范围使用服务器标识，优先核对任务、数据集、指标及训练条件，不能确认可比时不计算差值或排名。该设计改善结果组织，但条件抽取和事实核验仍可能出错，需以原文逐项复查。

## 六 总结与展望

### 6.1 项目总结

项目完成从多格式论文到可追溯回答的工程链路，并对文档、检索、生成、工具和运行过程建立实际记录。实验支持的主要发现是：在冻结题集和索引条件下，交叉编码器提高前五条证据覆盖，但 CPU 代价明显；分块与 Embedding 不存在被所有指标一致支持的单一最优项；提示词引用约束的收益应按维度和题目解释。本地标准模式的

实际流程可用，并不消除完整性、数值归属和引用支撑方面的质量短板。

## 6.2 困难与解决过程

文档布局与表格公式导致来源和阅读顺序难以保持，解决思路是统一来源块并保留物理位置，而不是生成不存在的精确结构。超长输入的 decode/re-encode 曾引起窗口膨胀，改用原 ID 分窗后完成实际模型验证。规划动作可能编造文档标识，因而将明确论文范围交由服务器固定，并保留工具失败及恢复路径。引用规则容易把来源存在误当语义正确，本报告将规则审校、量表质量评分和运行成功分别记录，保留未解决的例子。

## 6.3 研究限制与后续工作

评测仅覆盖一个专题 10 篇论文，题集及其相关性标注由助手整理；因此外部有效性有限。生成参数每条件 4 题，存在输出长度和运行顺序混杂，不能支持稳定参数最优或显著性结论。历史 359 片段的冻结成绩、342 片段生产语料及 29 片段独立流程验收。本地探针不等于并发负载测试，模型回答仍保留待核查项。

后续优先检查跨论文证据覆盖，在证据缺失时补检索或明确不足，再对数值计算与逐条引用作约束。在更大且经独立复核的题集上重复采样，固定硬件、版本和随机设置，分别评估质量、时延和资源成本。最后再依据受控证据调整默认分块、重排候选规模和采样参数，避免以单一小样本均分替代工程决策。

# 参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, 2020. https://arxiv.org/abs/2005.11401.

[2] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR, 2023. https://arxiv.org/abs/2210.03629v3.

[3] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval, 2009, 3(4):333–389. doi:10.1561/1500000019.

[4] Cormack G V, Clarke C L A, Büttcher S. Reciprocal Rank Fusion outperforms Condorcet and individual Rank Learning Methods. SIGIR, 2009:758–759. doi:10.1145/1571941.1572114.

[5] Chen J, Xiao S, Zhang P, et al. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. Findings of ACL, 2024:2318–2335. doi:10.18653/v1/2024.findings-acl.137. https://aclanthology.org/2024.findings-acl.137/.

[6] Dosovitskiy, Alexey; Beyer, Lucas; Kolesnikov, Alexander; et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021. arXiv:2010.11929v2. https://arxiv.org/abs/2010.11929v2.

[7] Touvron, Hugo; Cord, Matthieu; Douze, Matthijs; et al. Training data-efficient image transformers & distillation through attention. ICML, 2021. arXiv:2012.12877v2. https://arxiv.org/abs/2012.12877v2.

[8] Liu, Ze; Lin, Yutong; Cao, Yue; et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV, 2021. arXiv:2103.14030v2. https://arxiv.org/abs/2103.14030v2.

[9] Wang, Wenhai; Xie, Enze; Li, Xiang; et al. Pyramid Vision Transformer: A Versatile Backbone for Dense Prediction without Convolutions. ICCV, 2021. arXiv:2102.12122v2. https://arxiv.org/abs/2102.12122v2.

[10] Yuan, Li; Chen, Yunpeng; Wang, Tao; et al. Tokens-to-Token ViT: Training Vision Transformers from Scratch on ImageNet. ICCV, 2021. arXiv:2101.11986v3. https://arxiv.org/abs/2101.11986v3.

[11] Touvron, Hugo; Cord, Matthieu; Sablayrolles, Alexandre; et al. Going deeper with Image Transformers. ICCV, 2021. arXiv:2103.17239v2. https://arxiv.org/abs/2103.17239v2.

[12] Wu, Haiping; Xiao, Bin; Codella, Noel; et al. CvT: Introducing Convolutions to Vision Transformers. ICCV, 2021. arXiv:2103.15808v1. https://arxiv.org/abs/2103.15808v1.

[13] Chen, Chun-Fu; Fan, Quanfu; Panda, Rameswar. CrossViT: Cross-Attention Multi-Scale Vision Transformer for Image Classification. ICCV, 2021. arXiv:2103.14899v2. https://arxiv.org/abs/2103.14899v2.

[14] Graham, Ben; El-Nouby, Alaaeldin; Touvron, Hugo; et al. LeViT: a Vision Transformer in ConvNet's Clothing for Faster Inference. ICCV, 2021. arXiv:2104.01136v2. https://arxiv.org/abs/2104.01136v2.

[15] Bao, Hangbo; Dong, Li; Piao, Songhao; et al. BEiT: BERT Pre-Training of Image Transformers. ICLR, 2022. arXiv:2106.08254v2. https://arxiv.org/abs/2106.08254v2.

# 七 附录

## 7.1 实际代码结构与复现环境

```
src/
  core/          config, schemas, storage
  data_loader/   document adapters and source blocks
  chunking/      fixed, recursive, sentence/paragraph splitters
  retrieval/     embeddings, RRF, vector stores, reranking
  generation/    context, prompts, citations, cache, LLM clients
  agent/         registry, router, executor, memory, ReAct loop
  services/      application orchestration
  api/           HTTP and SSE endpoints
  frontend/      Streamlit workspace pages
  evaluation/    datasets, metrics, reviews, exports
scripts/         preparation, execution, reporting, acceptance
tests/           unit, API, frontend, and integration checks
docker/          unverified container deployment configuration
```

**表 28** 报告整理时记录的本地软件环境

| 组件 | 版本 | 组件 | 版本 |
|---|---|---|---|
| Python | 3.12.14 | PyTorch | 2.14.1 |
| FastAPI | 0.142.2 | Streamlit | 1.65.0 |
| Sentence Transformers | 5.7.0 | Transformers | 5.19.0 |
| Chroma | 1.5.9 | FAISS CPU | 1.15.1 |
| PyMuPDF | 1.28.2 | NumPy | 2.5.3 |

此表为实际本地环境快照；依赖声明中的版本区间与本表已安装版本不是同一概念。模型权重版本另由 manifest 和指纹记录。

本地运行环境使用 Windows 11 及 NVIDIA GeForce RTX 4060 Laptop GPU；Embedding 与重排配置为 CPU，Ollama 依据资源加载生成模型。仅将软件版本和启动条件作为本机复现信息，不把不同时间的全部实验假设为相同负载或相同模型驻留状态。仓库依赖清单、模型 manifest 与实验快照应联合使用；本报告文件夹只保存文档、图

表和复核数据，不打包模型权重或私有工作区标识。

## 7.2 本地运行与重新验收

新环境需要 Python 3.10—3.13（建议 3.12）和 Ollama。先在项目根目录安装模型运行依赖，并准备四种实验所需的编码与重排模型：

```
.\scripts\setup.ps1 -Python python -Models
.venv\Scripts\python.exe scripts/prepare_models.py --models BAAI/bge-m3
    BAAI/bge-large-zh-v1.5 moka-ai/m3e-base BAAI/bge-reranker-base --cache-
    dir data/models/hub
```

首次下载需要联网，实际权重 revision 写入`data/models/manifest.json`；严格复现时应使用清单对应的 snapshot，而不是把未来同名仓库视为相同权重。在单独终端设置 Ollama 监听地址后启动服务：

```
$env:OLLAMA_HOST = "127.0.0.1:11435"
ollama serve
```

便携版路径见`data/tools/ollama-manifest.json`。在应用终端指定同一模型服务地址，按固定 GGUF revision 下载、导入并验证生成模型：

```
$env:RAG_OLLAMA_URL = "http://127.0.0.1:11435"
.venv\Scripts\python.exe scripts/prepare_qwen_gguf.py all --ollama-url http
    ://127.0.0.1:11435 --model research-qwen:7b
```

该脚本核对分片 SHA256 并生成`data/models/local-llm.json`，启动器据此选择实际模型标签。模型和缓存已就绪的环境可直接启动；在应用终端执行：

```
.\scripts\start.ps1 -Profile standard -ApiPort 8000 -UiPort 8501 -ModelPort
     11435
.venv\Scripts\python.exe scripts/verify_local_deployment.py --api http
    ://127.0.0.1:8000 --ui http://127.0.0.1:8501 --evidence-dir reports/
    local/new-run --document data/corpus/cvt_2103.15808v1.pdf --timeout 900
```

每次验收使用新随机工作区，保存实际 HTTP 响应、SSE、原件哈希与预览，不复用旧通过标记。首次真实编码和模型加载可能明显慢于后续请求；记录应注明是否命中缓存及实际 token，而不是直接套用表24的单次耗时。

## 7.3 证据索引与课程要求对应

**表 29** 报告数值与实现证据索引

| 编号 | 内容 | 项目中的实际位置 |
|---|---|---|
| E01 | 固定论文版本 | data/corpus/manifest.json |
| E02 | 80 题与划分 | reports/datasets/dataset_manifest.json |
| E03 | 三解析器 | reports/experiments/retrieval/parsers/results.json |
| E04 | 五分块配置 | reports/experiments/retrieval/chunking/m3e/ |
| E05 | 编码与模型对比 | reports/experiments/retrieval/encoding/; reports/experiments/retrieval/chunking/bge-zh/ |
| E06 | 向量库 | reports/experiments/retrieval/vectorstores/ |
| E07 | 三档 test60 | reports/experiments/retrieval/m3/test/ |
| E08 | RRF 同题优化 | reports/experiments/retrieval/dev-parameters/results.json |
| E09 | 60 题评分 | reports/experiments/generation/baseline/ai_review_summary.json 及同目录逐题 CSV |
| E10 | 参数与 Prompt | reports/experiments/generation/quality-comparison/；原始记录在reports/experiments/generation/parameters/和reports/experiments/generation/prompt/ |
| E11 | Agent 探针 | reports/experiments/generation/agent/results.json |
| E12 | 并行与缓存 | reports/experiments/generation/parallel/和reports/experiments/generation/cache/ |
| E13 | 异质在线记录 | reports/experiments/online-functionality/results.json |

| 编号 | 内容 | 项目中的实际位置 |
|---|---|---|
| E14 | 本地实际验收 | reports/deployment/local-20261015/runtime-record.json 及reports/deployment/local-20261015/acceptance/acceptance.json |
| E15 | Bad Case | reports/experiments/bad-cases/actual-bad-cases.json |
| E16 | 已有测试记录 | reports/testing/；完整与定向测试时间分别保存，不叠加重叠数量 |
| E17 | 历史界面图 | docs/screenshots/；本文件夹保留原件及图表来源指纹 |

本报告文件夹中的data/report-data.json 保存原始制表与绘图快照，data/advanced-statistics.json 保存同题配对效果和评分分组等派生统计，figures/figure_manifest.json 记录图形及截图来源。课程要求中的多格式解析、三分块、两编码模型、三档检索、生成参数、八工具及四类 Bad Case 分别在第三、四部分对应展开。

## 7.4 图表与源文件编译

main.tex 为完整正文源文件，参考文献内嵌，不依赖外部 BibTeX；所有图像均从本文件夹的figures/ 相对引用。建议使用 XeLaTeX 连续编译两次，或使用支持 XeTeX 的 Tectonic；中文字体采用 TeX 发行版提供的 Fandol 仿宋，避免依赖仅存在于本机的中文字体。图表包含矢量 PDF 与可预览的高分辨率 PNG，原始界面图片保留在figures/original-ui/，标注只说明功能区域，不修改界面内容。正文按模板采用仿宋四号、1.5 倍行距及 A4 页边距；图注和结果表适度缩小，以保证图、文和数据的可读性。