南京农业大学

课程考核情况表

2026—2027 学年第 1 学期

学院	智慧农业学院（人工智能学院）
课程名称	生产实习
学分	1
考核方式	课程报告
考核内容	智能科研助理——基于 RAG 与 Agent 的论文知识库问答系统
学生姓名	赵志国、林骋、林弟伟
成绩	
教师签名	

实际提交日期：_____ （提交时填写）

生产实习课程报告

智能科研助理

基于 RAG 与 Agent 的论文知识库问答系统

姓名	班级	学号
赵志国	人工智能 231	11523122
林骋	人工智能 231	11523121
林弟伟	人工智能 232	11523120

智慧农业学院（人工智能学院）

南京农业大学

编制日期：2026 年 10 月 15 日

摘要

论文知识库问答既需要覆盖原文证据，也需要控制生成过程中的事实归属、引用位置与工具调用。本项目面向通用论文阅读任务，构建由文档处理、混合检索、检索增强生成、手写 Agent 控制及评测记录组成的科研助理。系统支持多格式导入、三种分块策略、向量与 BM25 候选融合、交叉编码器重排、流式回答和物理页引用；使用原始 token-ID 分窗处理超长输入，并记录模型、索引和配置指纹。在视觉 Transformer 专题的 10 篇固定版本论文上建立 80 题评测集，区分 20 题开发集与 60 题测试集。历史 359 片段索引上的测试结果显示，向量检索、混合检索和混合加重排的 Hit@5 分别为 0.4167、0.4333 和 0.6167；CPU 重排同时带来较明显的时延代价。60 条实际短答案的 AI 辅助评审显示，流畅性均分为 4.58，而完整性和引用支撑分别为 2.98 和 3.03，表明证据覆盖与断言约束仍是主要瓶颈。四题提示词对照中，引用支撑均分由 2.50 增至 3.50，正确性均分不变；该结果仅作为小样本探索性观察。本地标准模型流程完成 33 类实际检查，覆盖论文导入、真实生成、引用预览及记录保存。本文分别报告历史索引、现有生产语料和独立流程验收的适用范围，不将 AI 评分表述为独立人工盲评，也不将单次运行或功能探针外推为总体性能结论。

关键词：检索增强生成；工具调用；论文知识库；混合检索；可追溯评测

Abstract

This project develops a research assistant that combines retrieval-augmented generation with explicit tool orchestration. The implementation preserves document locations across parsing, chunking, retrieval, generation, and citation inspection, while recording model and index fingerprints. A benchmark of 80 source-checked questions is constructed from ten fixed-version Vision Transformer papers, with 20 development and 60 test questions. On a historical frozen index of 359 chunks, Hit@5 increases from 0.4167 for dense retrieval to 0.6167 with hybrid retrieval and cross-encoder reranking, at a substantial CPU latency cost. AI-assisted assessment of 60 generated short answers reveals stronger fluency than completeness or citation support. A four-question prompt comparison improves mean citation support from 2.50 to 3.50 without changing mean correctness; the sample is insufficient for claims of general superiority. An independent local workflow passes 33 categories of operational checks, including real PDF ingestion, model generation, citation preview, and persistence of interaction records. Historical retrieval evaluation, generation-only studies, and current local acceptance are reported separately. AI-assisted ratings are identified by provenance, and operational success is not interpreted as semantic verification of every answer.

Keywords: retrieval-augmented generation; tool orchestration; paper knowledge base; hybrid retrieval; traceable evaluation

目 录

摘要 I

Abstract II

一 项目概述 1

1.1 项目背景 1

1.2 任务定义与项目目标 1

1.3 技术栈与实现边界 1

二 团队分工说明 2

三 模块交付物清单 2

四 技术实现记录 5

4.1 体系结构与数据流 5

4.2 文档解析分块与超长输入处理 5

4.3 混合检索与重排算法 6

4.4 证据约束生成引用与缓存 7

4.5 手写 Agent 与八工具协同 8

4.6 交互实现与功能区说明 10

4.7 评测设计与指标定义 12

4.8 解析分块模型与向量库实验 15

4.9 三档检索消融与参数迭代 18

4.10 答案质量生成参数与提示词比较 23

4.11 Agent 效率与本地运行验收 27

4.12 Bad Case 分析与优化边界 30

五 技术设计文档 **32**

5.1 模块接口与持久化 32

5.2 配置与可复现控制 32

5.3 隔离错误与安全边界 34

5.4 扩展设计的价值与限制 34

六 总结与展望 **34**

6.1 项目总结 34

6.2 困难与解决过程 35

6.3 研究限制与后续工作 35

参考文献 **35**

七 附录 **38**

7.1 实际代码结构与复现环境 38

7.2 本地运行与重新验收 39

7.3 证据索引与课程要求对应 40

7.4 图表与源文件编译 41

一 项目概述

1.1 项目背景

科研阅读需要在多篇论文之间核对方法、训练条件和实验结果。仅依赖语言模型记忆容易产生事实与来源不一致的问题，单纯关键词检索又难以直接完成归纳和比较。因此，项目将可定位的论文证据检索与受约束的生成、计算和工具协同结合，以支持可复查的科研问答。

1.2 任务定义与项目目标

设当前工作区论文集合为 $\mathcal{D}$，问题为 q，有界会话历史为 H，系统输出为

$$(a, \mathcal{C}, \mathcal{L}) = F(q, H, \mathcal{D}; \theta), \tag{1}$$

其中 a 为答案，$\mathcal{C}$ 为绑定原文位置的来源集合，$\mathcal{L}$ 为实际执行与资源记录，θ 包含模型、索引和生成配置。项目目标是使文档可导入、证据可检索、回答可引用、动作可观察、实验可复核。检索分数不解释为事实正确性的概率，来源编号存在也不等价于该来源支持全部断言。

RAG 通过外部检索证据补充生成模型的参数知识 [1]；ReAct 提供动作与观察交替的工具使用范式 [2]。本文据此实现可检查的编排过程，而不是以现成 Agent 框架替代课程要求的核心控制逻辑。系统面向通用论文知识库，评测专题限定为视觉 Transformer 架构、训练与数据效率，不把专题限制固化为产品使用范围。

1.3 技术栈与实现边界

服务层采用 FastAPI，交互层采用 Streamlit，状态数据保存于 SQLite；文档适配器使用 PyMuPDF、pdfplumber、PyPDF2 及

python-docx。向量编码与交叉编码器推理由 Sentence Transformers 提供，向量存储适配 Chroma 与 FAISS，稀疏检索调用 BM25Okapi。本地生成通过 Ollama 调用 Qwen2.5-7B-Instruct 的 Q4_K_M 权重，实际模型标签为 `research-qwen:7b`。项目自行实现分块来源传播、RRF 融合、原 token-ID 窗口控制、引用规则审校、缓存准入和工具控制器。联网搜索属于课程可选能力，未将其作为八个本地工具之一。

二 团队分工说明

表 1 成员分工安排与约定贡献比例

角色	姓名	核心职责安排	模块	比例
检索与 RAG	赵志国	文档处理、证据检索、生成与服务编排	文档与问答	40%
Agent 与工具	林骋	工具注册、路由、记忆及异常终止控制	Agent	30%
交互与评测	林弟伟	页面流程、实验整理、文档与展示材料	集成与评测	30%

表1的姓名、班级、学号与贡献比例依据小组提供的信息整理，比例合计 100%。职责细分为本报告采用的分工安排，提交前应由成员按实际工作确认。现有仓库保存真实版本历史，但不能据此推断三位成员各自的独立提交数量；本文不以自动生成记录代替个人工作量证明。

三 模块交付物清单

交付状态区分代码实现、真实执行和评价来源。以下五表对应课程模块，不将“提供脚本”视为“已完成环境验收”。

表 2 模块一文档处理与检索交付物

交付项	状态	证据与范围
多格式解析与三解析器	已实现	PDF、DOCX、TXT、MD；10 篇论文的 30 次解析记录，E03
三类分块与长度比较	已实现	固定 256/512/1024、递归、句段边界；同 20 题 dev，E04
两类 Embedding 比较	已实现	m3e 与 BGE-large-zh；生产另用 BGE-M3，E05
向量库与混合重排	已实现	Chroma/FAISS、BM25、手写 RRF 及 CrossEncoder，E06—E08

表 3 模块二 RAG 问答交付物

交付项	状态	证据与范围
提示词与上下文构造	已实现	预算控制、论文轮转、来源同步裁剪，E10
SSE 与引用追溯	已实现	增量回答、物理页预览、原件哈希核对，E14
缓存与失败处理	已实现	指纹约束准入、精确重复探针、显式降级，E12
生成参数质量比较	已完成 AI 评审	五条件各 4 题；不作独立人工或显著性声明，E10

表 4 模块三 Agent 交付物

交付项	状态	证据与范围
手写执行控制器	已实现	schema 校验、工具动作与观察、有界终止
八项本地工具	已实现	问答、元信息、比较、关键词、摘要、时间、计算和目录
记忆与错误恢复	已实现	会话隔离、窗口与摘录记忆、受限重试
路由与并行探针	已实测	5 个路由样本；20 次本地工具执行，E11、E12

表 5 模块四集成与交互交付物

交付项	状态	证据与范围
四个工作台页面	已实现	论文库、问答、比较、实验与运行记录
会话及文档管理	已实现	上传进度、重试、元信息、会话搜索与导出
运行追踪与统计	已实现	状态、用量、模型与检索配置快照
本地标准模式验收	已通过	33 类实际检查、0 失败；单篇 CvT 独立工作区，E14

表 6 模块五评测与材料交付物

交付项	状态	证据与范围
语料与评测题集	已建立	10 篇固定论文、80 题、四类问题，E01、E02
检索指标与 Bad Case	已执行	三档 test60、四类错误、优化前后记录，E07、E15
答案质量评分	部分满足原要求	60 题 AI 辅助评分已完成；独立人工评分未执行，E09
文档及演示材料	已提供	报告、设计、手册、实验附件与演示稿
Docker 部署	文件已提供	本报告采用本地验收；容器构建及运行未实测

四 技术实现记录

4.1 体系结构与数据流

系统将文档处理路径与问答路径分开：前者形成可定位的片段和索引，后者在指定范围内检索、编排证据并产生回答。SQLite 保存文档、会话、运行与实验元数据，向量库保存可按工作区过滤的编码结果。原文物理页与字符来源贯穿整个流程，使回答中的来源编号可以回到实际文件，而不是停留在模型生成的参考文献文字。图1展示模块及其数据关系。

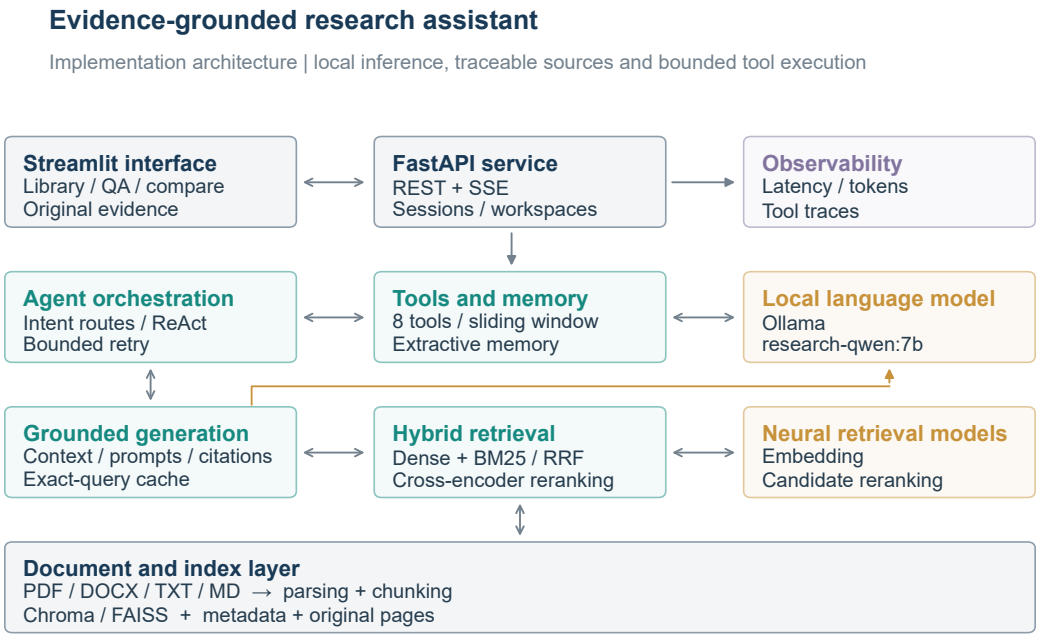


图 1 论文知识库与 Agent 系统的数据流。原文位置、配置指纹和执行记录与正文处理链路共同保存；框架能力与项目控制逻辑在实现中分开。

4.2 文档解析分块与超长输入处理

PDF 解析输出统一来源块。能够获取布局信息的适配器保留物理页与边界框，阅读顺序采用全宽块划分阅读带、带内先左后右的启发式方法。表格以逐行文本保存，公式保留可提取的 Unicode 及上标信息，跨页来源分别记录。这些处理适用于具有文本层的 PDF，

不能表述为通用 OCR、完整版面理解或无损公式重建。DOCX 按正文顺序读取段落和表格；缺失作者、年份或 DOI 时保留缺失状态。

固定窗口、递归边界和句段边界三类分块分别控制长度、优先保持文本边界及利用段落/句末结构。递归策略实际调用 `RecursiveCharacterTextSplitter` 提出边界，再检验字符偏移和原子结构约束。句段策略未使用 Embedding 模型预测语义边界，因此不将其描述为学习式语义切分。默认长度 512、重叠 64，单位是项目定义的汉字、英文词或独立符号，与模型原生 tokenizer 分别管理。

为避免模型输入超限时静默截尾，编码器直接在原始 token-ID 序列上分窗，扣除特殊 token 预算，不进行 decode 再 encode 往返。设第 j 个窗口含 w_j 个原始 token，模型输出 $f(x_j)$，片段编码为

$$u_j = \frac{f(x_j)}{\max(\|f(x_j)\|_2, \epsilon)}, \tag{2}$$

$$v(d) = \operatorname{norm}\left(\frac{\sum_{j=1}^{m} w_j u_j}{\sum_{j=1}^{m} w_j}\right). \tag{3}$$

实现覆盖全部窗口并检查输入约束；加权聚合并不等价于无限上下文编码。模型缓存版本、窗口策略版本与窗口上限纳入指纹，以阻止不同编码策略误用已有向量。

4.3 混合检索与重排算法

密集检索使用归一化向量内积；Chroma 的 cosine 距离转换为 $1 - \text{distance}$，FAISS 使用精确 `IndexFlatIP`。稀疏检索采用 jieba、中文二元组与技术标识英文切分后调用 BM25Okapi[3]：

$$B(q,d) = \sum_{t \in q} \widetilde{\mathrm{IDF}}(t) \frac{f(t,d)(k_1+1)}{f(t,d) + k_1(1 - b + b|d|/\overline{|d|})}. \tag{4}$$

实际默认 $k_1 = 1.5$、$b = 0.75$；原始 IDF 采用 $\log[(N - n_t + 0.5)/(n_t + 0.5)]$，负值按库实现替换为平均 IDF 的 0.25 倍。本文据实际实现描述公式，不改写为另一种恒正 IDF 形式。

项目手写 RRF 仅使用候选名次，以避免不同检索分数的量纲影响 [4]：

$$R(d) = \sum_{r \in \{\text{dense,BM25}\}} \frac{\mathbb{I}[d \in L_r]}{k_0 + \text{rank}_r(d)}. \tag{5}$$

名次从 1 开始，每路先去重，默认 $k_0 = 60$；同分按片段标识稳定排序。每路候选数默认 20，融合后保留候选池，再返回 5 条或进入交叉编码器。融合没有对原始分数做 min–max 归一化。

重排使用 BGE-reranker-base 联合编码问题与候选；长文档保留完整问题，以原 token-ID 窗口计算 logit 并取最大值：

$$z(q,d) = \max_j g(q,d_j), \qquad s(q,d) = \frac{1}{1 + \exp[-z(q,d)]}. \tag{6}$$

s 是单调阈值分数，未经概率校准；最大窗口聚合可能高估单个相关窗口的代表性。重排失败时保留 RRF 顺序并记录降级原因，避免把未执行的重排记为成功。生产环境采用 BGE-M3 编码 [5]，与模块实验中的 m3e 和 BGE-large-zh 比较分别报告。

4.4 证据约束生成引用与缓存

上下文构造扣除系统提示、历史、问题与预留开销后分配证据预算，按论文分组轮转以减少单篇来源挤占。裁剪正文时同步裁剪来源及页区间；预算采用保守字符估算，模型服务返回的真实 token 另行记录。默认上下文预算 4096、生产输出预算 768；生成对比实验为 256 输出 token，二者不可混同。

服务器给来源分配 `[S1]` 等编号，绑定文档、片段、物理页和可用边界框。生成后规则审校检查引用编号、数字对应和部分相邻页码

表达，但不证明语义蕴涵。无结果时明确标注普通模型回答，低相关度时提示核查，模型失败时保留失败状态或原文摘录降级状态。SSE 传递状态、来源、文本增量、用量与结束事件；多工具路径的综合回放与单一 RAG 的模型增量在事件中区分。

缓存首先匹配索引、模型、生成配置、文档范围、历史与提示词指纹，再检查问题匹配及相似度阈值。默认阈值 0.96，并约束数字、英文锚点、否定及意图一致；有待核查引用、时效或指代问题不写入缓存。索引变化使旧指纹失效。此机制降低错误复用风险，但一次精确重复探针不足以测量总体缓存命中率。

4.5 手写 Agent 与八工具协同

注册表对工具名称、必填参数、类型和长度执行 schema 校验。八项工具的作用见表7。

表 7 工具注册表及边界

工具	能力与限制
knowledge_qa	指定论文范围内的证据问答
paper_metadata	读取实际保存的题名、作者、年份等字段
compare_papers	两篇论文的结构化比较；条件不齐时不直接排名
extract_keywords	文档或输入的词频候选，不把词频当论文结论
summarize_paper	依据证据生成结构化摘要
current_time	返回实际系统时间
calculator	白名单算术 AST 解释，不执行任意 Python
paper_catalog_search	查询当前本地论文目录，不冒充互联网搜索

Agent 的 System Prompt 将角色限定为基于本地论文库的科研助理，要求先调用工具查证，再依据已返回的来源回答。工具说明及参数 schema 由注册表附入模型请求；原生工具调用不可用时，仅接受包含 `tool_calls` 的严格 JSON 动作。提示词约束论文标识来自

当前范围、引用仅使用工具返回编号、独立动作可并行、依赖动作须等待观察，并禁止重复同参调用及隐瞒失败。论文正文和工具结果被视为数据；最终回答不输出内部思维链，数值比较须说明任务、数据划分与指标条件。这些约束与服务器的范围校验、动作去重及步数预算共同生效，不能仅凭提示词保证执行安全或内容正确。

控制器采用快捷路由与有界模型规划结合的实现。一般概念可走显式模型常识路径，单一论文事实问答进入流式 RAG；其余任务由动作和工具观察交替推进。两篇论文已被明确选定时，服务器固定比较范围，避免规划阶段编造文档标识。独立工具可在受限线程池并行，存在依赖的动作等待前一步结果；并非每个问题都执行多轮规划。规划不可用时采用透明的本地路由，不将快捷路径伪装为复杂 Agent 推理。

默认最多 6 步，限制单工具与请求总预算，按工具名和规范化参数检测重复动作。仅在原调用已结束且属于临时错误时允许有界重试；超时但仍运行的线程继续占用槽位，避免推测性副本。会话记忆由近期窗口与旧消息抽取摘录组成，默认最多 8 条近期消息、1400 个估算 token；派生记忆与原消息分开保存。公开日志只呈现动作、参数、结果、耗时和状态，不输出模型内部思维链。

表 8 范围与预算约束下的证据增强执行过程

步骤	执行逻辑
1	校验工作区和就绪文档范围，读取有界会话记忆。
2	判定普通模型、单一 RAG 或工具循环路径，并记录所选路径。
3	对知识检索生成 dense 与 BM25 候选，按名次执行 RRF，可选窗口重排。
4	按论文轮转编排来源、分配编号，执行上下文与位置同步裁剪。
5	调用实际模型，输出 SSE 增量，审校来源编号及数字断言。
6	对多工具任务校验动作 schema，执行受限并行、错误恢复与终止检查。
7	保存回答、来源、模型与索引快照及已知/未知用量，返回完整或部分结果。

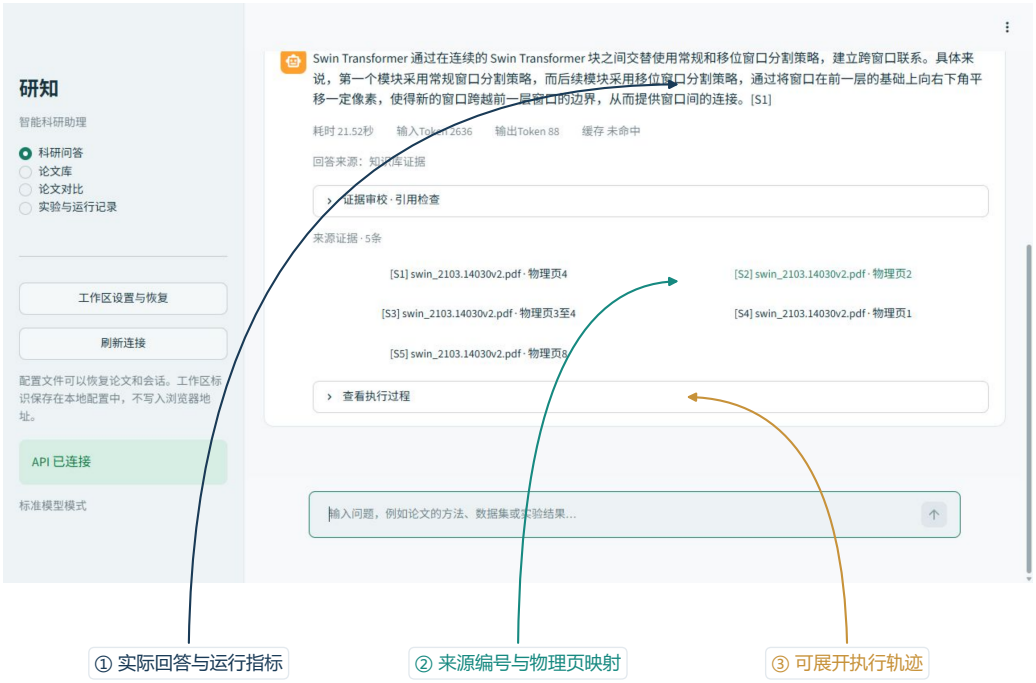
4.6 交互实现与功能区说明

界面由科研问答、论文库、论文对比、实验与运行记录四页组成。文档导入呈现批量任务进度和重试，论文库提供元信息编辑、片段与原文查看；问答提供会话、范围、答案、来源和执行轨迹，运行页保留用量与实验配置。以下四张为 2026 年 10 月 10 日留存的真实界面实现截图，按功能区作外部标注，保留原图内容。它们用于说明界面结构，不作为 10 月 15 日新运行问题的回答证据；后者由独立 HTTP 记录和本地就绪截图支持。



2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

图 2 论文库的文档管理、索引状态和操作区域。历史真实界面截图，日期为 2026 年 10 月 10 日；标注不改变原图内容。



2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

图 3 科研问答的会话与范围、答案和证据区域。截图中的历史回答不是本轮新生成结果，也不代表内容已经通过完整语义评分。



2026-10-10 历史运行截图 · 仅外部标注功能区 · 保留原始页面内容

图 4 论文对比的文档选择、比较维度与结构化结果区域。实验条件不完整时，界面保留不直接计算差值和排名的限制。

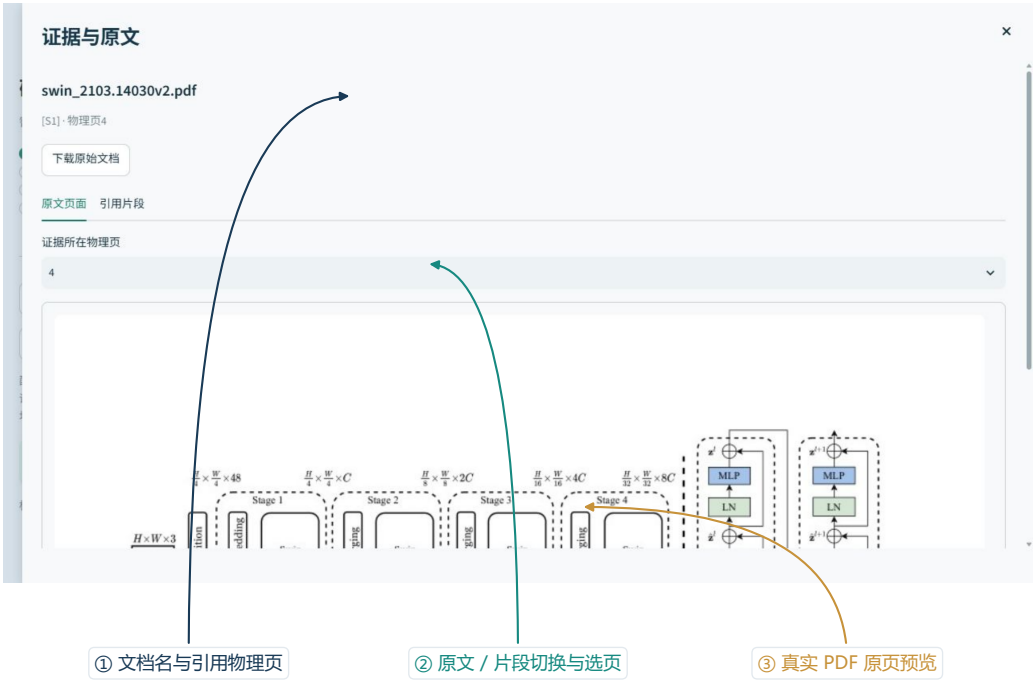


图 5 原文证据抽屉的来源、物理页和正文预览区域。页码依据服务器保存的原文元数据，而不是模型自行填写。

4.7 评测设计与指标定义

4.7.1 语料与题集

选择视觉 Transformer 作为评测方向，收集表9中的 10 篇固定版本论文，涵盖架构、数据效率与训练策略。语料共 169 个物理页，保存原始文件哈希；任务是检索论文信息，不复现论文模型的训练或分类准确率。

参考答案和相关来源由助手依据本地论文逐题核对，相关性采用短文本锚点及物理页、来源段落约束。锚点匹配便于复查，但可能遗漏语义等价证据，也可能把含有短锚点的邻近段落判为相关。题集由开发和资料整理过程接触过的标注构成，因此本文不将测试结果描述为独立多人建立、完全不可见的盲测。

表 9 固定版本论文语料及物理页数

论文简称	固定 arXiv 版本	发表信息	物理页
VIT[6]	2010.11929v2	ICLR 2021	22
DEIT[7]	2012.12877v2	ICML 2021	22
SWIN[8]	2103.14030v2	ICCV 2021	14
PVT[9]	2102.12122v2	ICCV 2021	15
T2T[10]	2101.11986v3	ICCV 2021	10
CAIT[11]	2103.17239v2	ICCV 2021	30
CVT[12]	2103.15808v1	ICCV 2021	10
CROSSVIT[13]	2103.14899v2	ICCV 2021	12
LEVIT[14]	2104.01136v2	ICCV 2021	16
BEIT[15]	2106.08254v2	ICLR 2022	18

总计 10 篇、169 个 PDF 物理页。发表年份与 arXiv 首次提交年份分别保留；引用与页码均对应表列固定版本。来源 E01。

表 10 题集构成与固定划分

题型	开发集	测试集	总计
事实型	8	22	30
比较型	4	16	20
综合型	4	11	15
推理型	4	11	15
合计	20	60	80

开发集用于配置探索；全部标签在资料整理阶段已由助手接触，测试集结果不作为独立盲测。来源 E02。

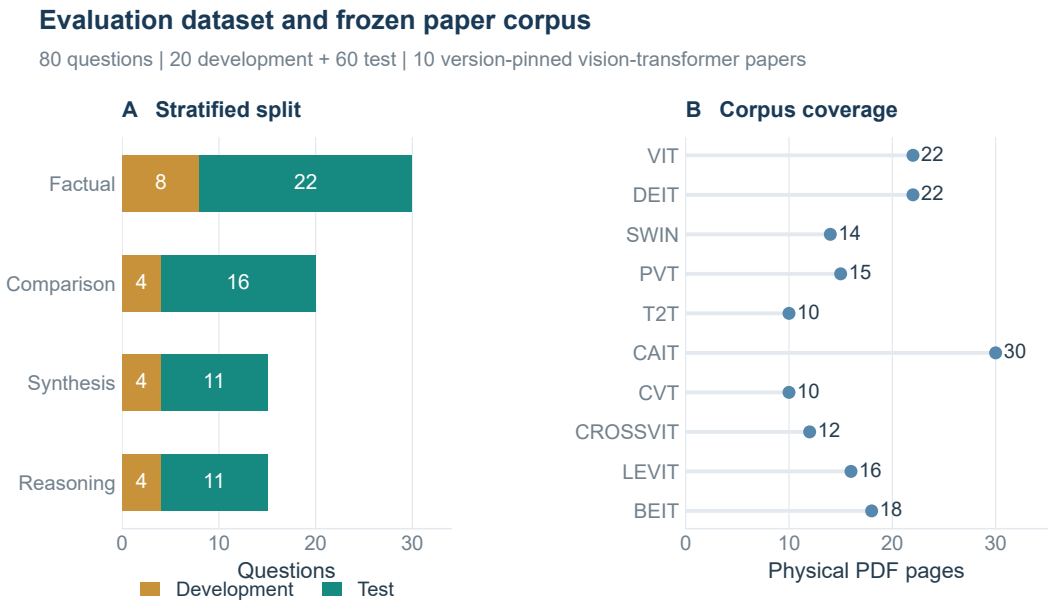


图 6 四类问题的开发集和测试集构成。开发集 20 题、测试集 60 题；数量来自固定题集记录。

4.7.2 指标与比较条件

设第 i 题的标注来源证据单元集合为 G_i，前 K 条检索结果覆盖的来源证据单元集合为 $R_i^{(K)}$，首个相关项名次为 r_i。本项目报告

$$\mathrm{Hit@K} = \frac{1}{n}\sum_{i=1}^{n} \mathbb{I}[R_i^{(K)} \cap G_i \neq \varnothing], \tag{7}$$

$$\mathrm{Recall@K} = \frac{1}{n}\sum_{i=1}^{n} \frac{|R_i^{(K)} \cap G_i|}{|G_i|}, \tag{8}$$

$$\mathrm{MRR} = \frac{1}{n}\sum_{i=1}^{n} \frac{\mathbb{I}[r_i < \infty]}{r_i}. \tag{9}$$

实际相关项匹配遵循源记录中的文档、物理页及锚点规则；MRR 使用实验候选深度内首个相关项，而不是自动视为 MRR@5。路由 exact-match 只比较预期工具集合与实际工具选择；用量与延迟分别保存已知 token、估算标记和时间范围。质量评分采用正确性、完整性、引用支撑与流畅性四维 1—5 分量表，保留 AI 辅助评审的真实来源。

正式三档检索和短答案生成使用历史 359 片段索引；分块/Embedding 比较中的递归索引与 10 篇生产语料为 342 片段；本轮本地运行验收为独立 CvT 工作区 29 片段。这些版本不能合并为一次统一端到端实验。三档检索复用已真实编码的查询向量，生成研究复用真实命中，不能用其计时替代在线完整路径。

4.8 解析分块模型与向量库实验

表 11 三种 PDF 解析器的实测结果

解析器	累计耗时/s	锚点保持	表格块	公式块
pymupdf	38.565	119/119	157	119
pdfplumber	29.251	119/119	141	231
pypdf2	9.124	114/119	0	1

每个解析器处理相同 10 篇论文；锚点保持率是代理指标，不代表完整版面、表格或公式识别准确率。来源 E03。

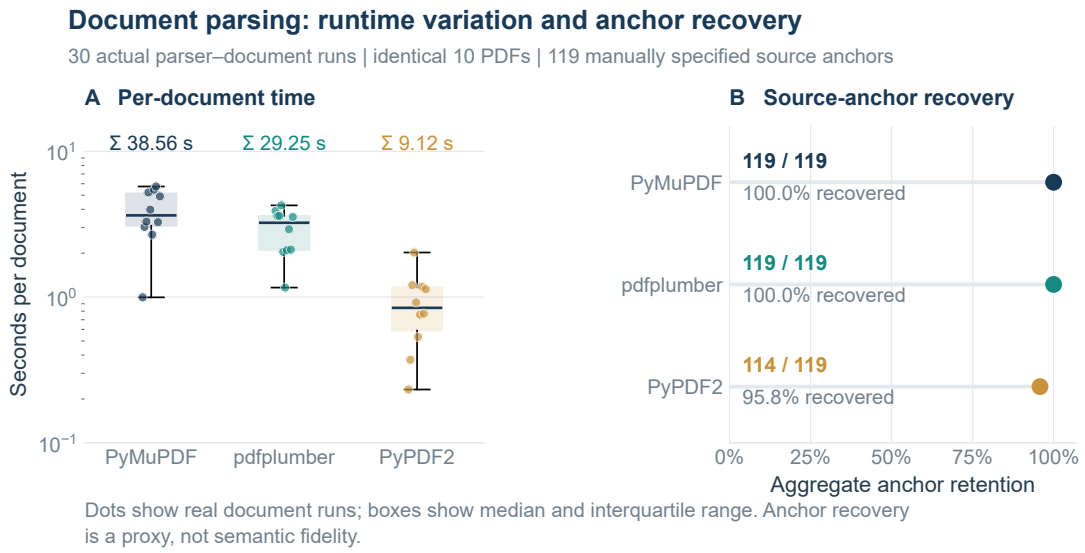


图 7 相同 10 篇论文上的解析累计耗时和 119 个来源锚点保持率。检测块数与锚点保持均不是完整语义识别率。来源 E03。

PyPDF2 的累计耗时较低，但锚点保持为 114/119，且缺少块级坐标；其表格和公式块检测数量不能与布局解析器简单等价。PyMuPDF 与 pdfplumber 均保留全部既定锚点，也不能由此推断所

有阅读顺序、表格或公式均正确。

表 12 同一 m3e 模型下的五种分块配置比较

分块配置	片段数	Hit@5	MRR	Recall@5
fixed-256	724	0.3500	0.2921	0.3250
fixed-512	314	0.4000	0.2699	0.3750
fixed-1024	150	**0.5000**	**0.3604**	**0.4000**
recursive-512	342	0.4000	0.2785	0.3500
semantic-512	326	0.4500	0.3078	**0.4000**

开发集 20 题；混合检索（Dense、BM25 与 RRF），每种切分使用其实际索引。分块单位为项目定义的轻量 token，不等同于模型 tokenizer。来源 E04。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

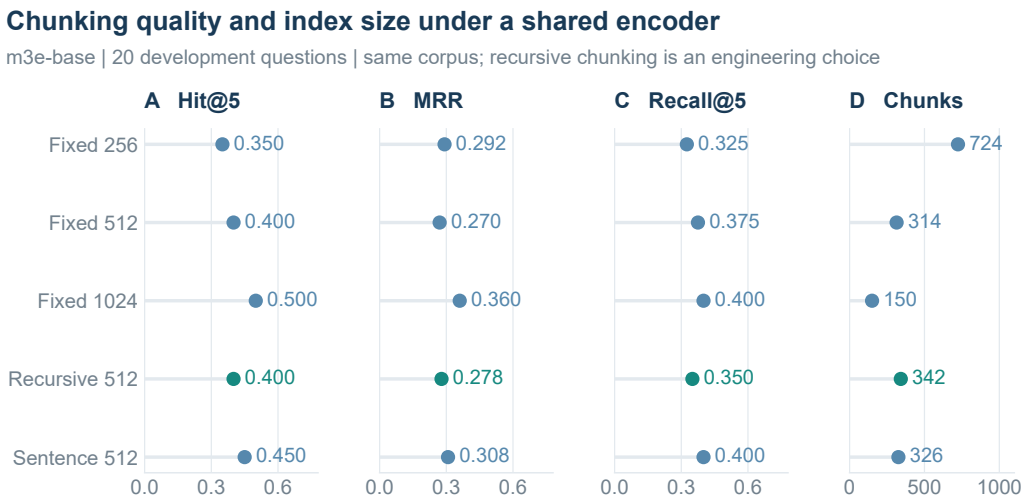


图 8 同一 m3e 模型和 20 题开发集上的分块配置比较。每个切分方案具有自己的真实片段索引。来源 E04。

固定 1024 在该开发集的 Hit@5 和 MRR 最高，递归 512 没有取得最高指标。生产选择递归策略是来源结构、上下文预算与工程一致性的折中，不以实验数据未支持的“最优切分”解释。长块可能增加包含相关锚点的机会，也可能稀释局部语义，因此需在更多题目与上下文预算下重复比较。

m3e 的 Hit@5 为 0.4000，高于 BGE-large-zh 的 0.3500；后者 MRR 较高，说明命中与排序指标需要分别解释。文档编码吞吐统计

表 13 Embedding 模型质量与查询编码代价

模型	维度	Hit@5	MRR	Recall@5	编码/ms
m3e-base	768	**0.4000**	0.2785	**0.3500**	43.94
bge-large-zh-v1.5	1024	0.3500	**0.2960**	0.3000	212.43

同 342 片段、开发集 20 题、递归 512 配置。最后一列为 20 个实际查询的编码总时间除以 20，不包含模型加载，亦不是逐请求在线延迟。此表没有比较 BGE-M3。来源 E05。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

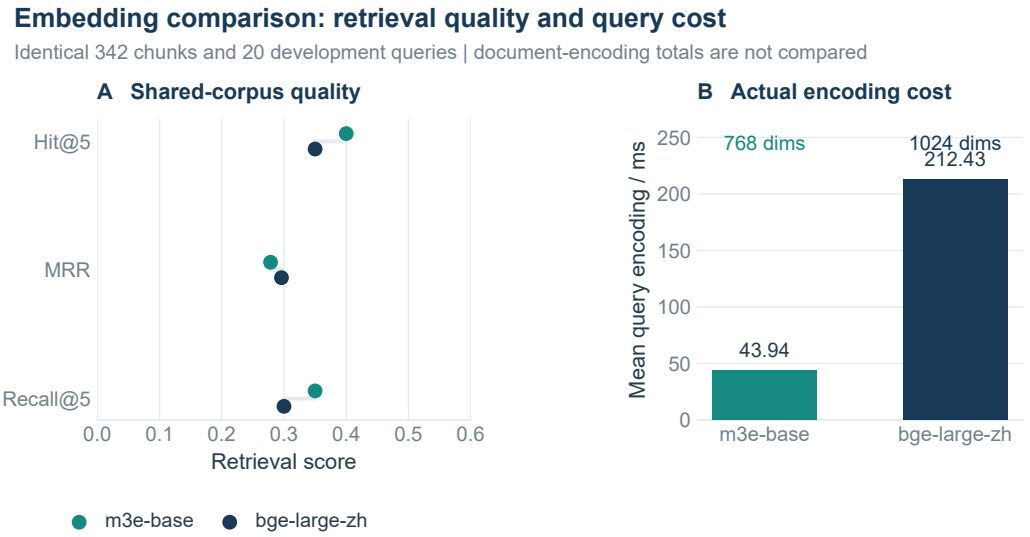


图 9 一致递归索引下的模型质量与 20 题查询编码摊销时间。m3e 和 BGE-large-zh 的 MRR 及 Hit@5 各有差异，不能单一排序为全面优劣。来源 E05。

的文本集合不同：m3e 覆盖五种切分去重后的 1836 条，BGE-large 为递归方案 342 条，因而不作同分布吞吐结论。

表 14 相同真实向量下的存储后端比较

后端	构建/ms	查询均时/ms	Hit@5	MRR	Recall@5
chroma	1165.03	2.291	**0.3500**	**0.3236**	**0.2750**
faiss	156.44	6.246	**0.3500**	**0.3236**	**0.2750**

历史 359 片段、1024 维真实向量及同 20 个开发集查询；查询时间排除共享编码。删除与恢复探针均通过。规模有限，不能据此证明后端普遍优劣。来源 E06。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

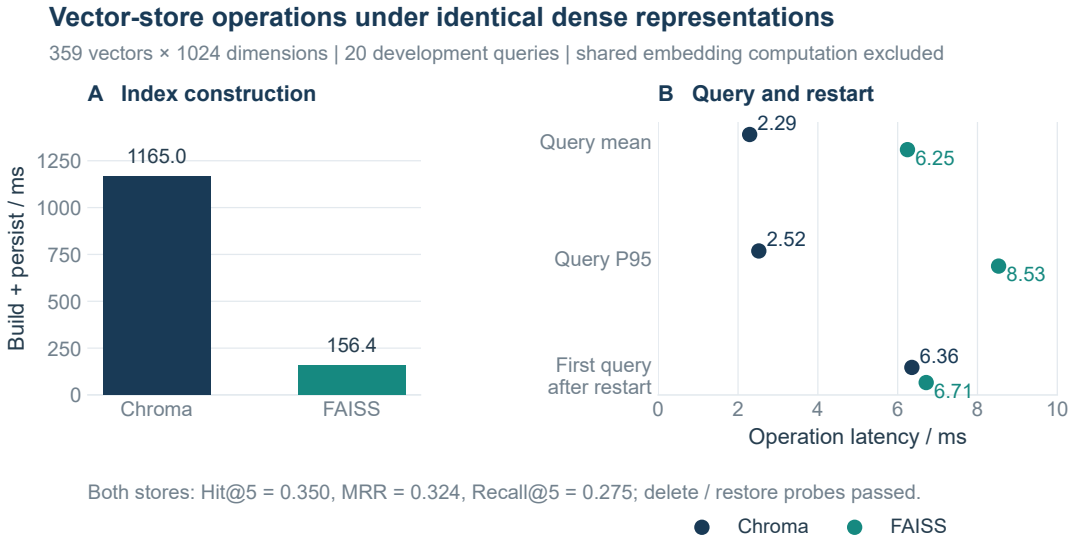


图 10 同一 359 片段与真实向量的后端质量和查询耗时。后端比较复用模型推理，结果仅代表当前规模与实现。来源 E06。

两个后端得到相同的检索质量，但持久化构建和查询耗时不同。这些结果主要用于验证后端可替换性和本机行为，不足以推断大规模吞吐、召回近似误差或生产集群优势。

4.9 三档检索消融与参数迭代

混合加重排的 Hit@5 较纯向量提高 20.00 个百分点，较混合 RRF 提高 18.33 个百分点，Recall@5 也提高。但其 CPU 排序均时约 16.7 秒，显著高于预编码向量的纯检索阶段；不能将纯向量 3.20 ms 写

表 15 冻结测试集上的三档检索结果

模式	Hit@5	MRR	Recall@5	均时/ms	P95/ms
向量	0.4167	0.2992	0.3250	3.20	4.03
混合 RRF	0.4333	0.3538	0.3583	8.27	10.31
混合加重排	**0.6167**	**0.4313**	**0.4750**	16708.41	18625.26

每模式 60 题，历史 359 片段；各模式执行错误数均为 0。预计算查询编码不包含在排序耗时内；BGE-M3 全部 80 题查询编码均摊为 112.915 ms/题。来源 E07。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

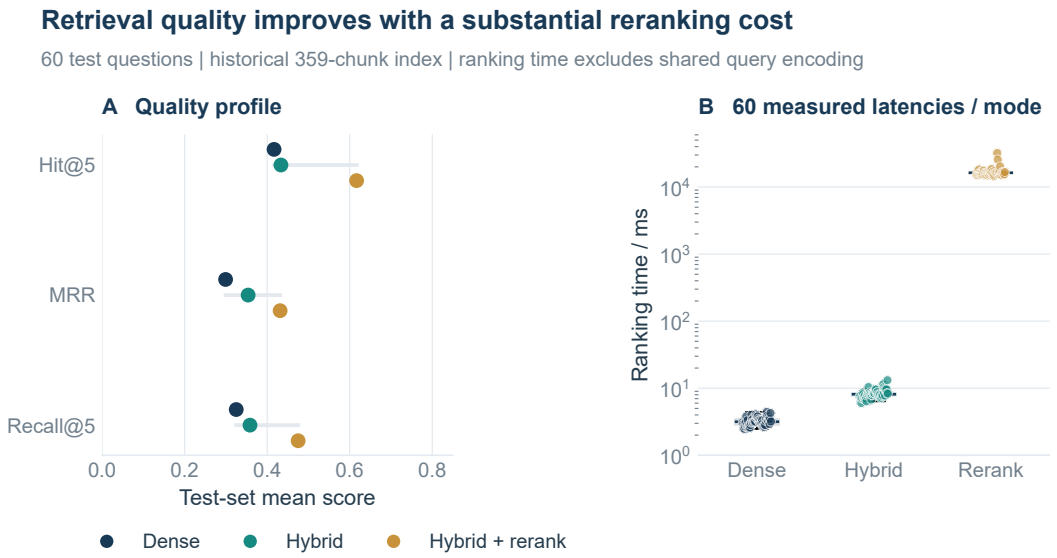


图 11 同一历史 359 片段与 60 题测试集上的检索模式消融。重排提高证据覆盖，同时引入 CPU 推理成本。来源 E07。

成在线问答时延。误差区间采用对实际题目进行 5000 次 percentile bootstrap、固定随机种子 20261015。图12表示题目抽样不确定性，不是模型多次运行方差，也不据此宣称统计显著。 图13进一步使用同

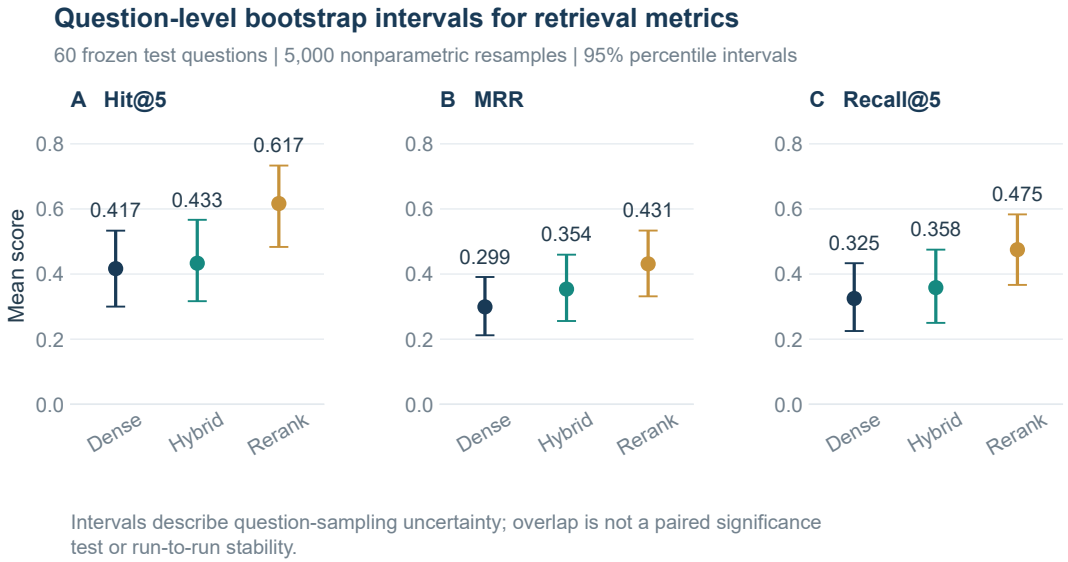


图 12 60 题逐题重采样的 95% percentile 区间。每个模式使用同样的实际问题集合；区间不替代重复运行或配对显著性检验。来源 E07。

一题目的模式差值，三组比较的每次重采样均保留题目配对关系。差值及其 95% 区间用于描述本题集上的效果与题目构成不确定性，不作显著性判定。

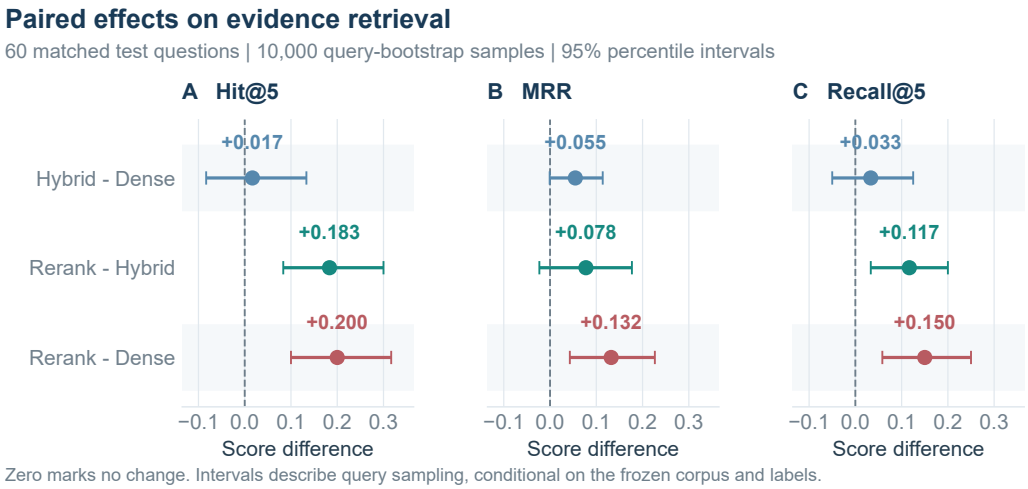


图 13 三组检索模式比较的配对效果。横轴为后者减前者的指标差，线段为题目级配对 bootstrap 的 95% 区间。图中均采用 0—1 指标的原量纲差值；Hit 与 Recall 在表16换算为百分点，MRR 不换算。来源 E07 及派生统计快照。

表 16 同题配对的检索效果差及其题目级区间

比较（后者减前者）	指标/单位	Δ	95% 区间
向量 → 混合	Hit@5/百分点	+1.67	[-8.33, 13.33]
向量 → 混合	MRR/原量纲	+0.0546	[-0.0008, 0.1139]
向量 → 混合	Recall@5/百分点	+3.33	[-5.00, 12.50]
混合 → 混合 + 重排	Hit@5/百分点	+18.33	[8.33, 30.00]
混合 → 混合 + 重排	MRR/原量纲	+0.0775	[-0.0231, 0.1770]
混合 → 混合 + 重排	Recall@5/百分点	+11.67	[3.33, 20.00]
向量 → 混合 + 重排	Hit@5/百分点	+20.00	[10.00, 31.67]
向量 → 混合 + 重排	MRR/原量纲	+0.1322	[0.0428, 0.2266]
向量 → 混合 + 重排	Recall@5/百分点	+15.00	[5.83, 25.00]

各比较使用同 60 题；同次抽样索引应用于全部模式。10000 次 percentile 重采样，seed=20261017。混合指 RRF 融合；Hit 与 Recall 列按百分点换算，MRR 不换算。区间仅刻画题目构成不确定性，不作显著性检验。来源 E07 及派生统计快照。

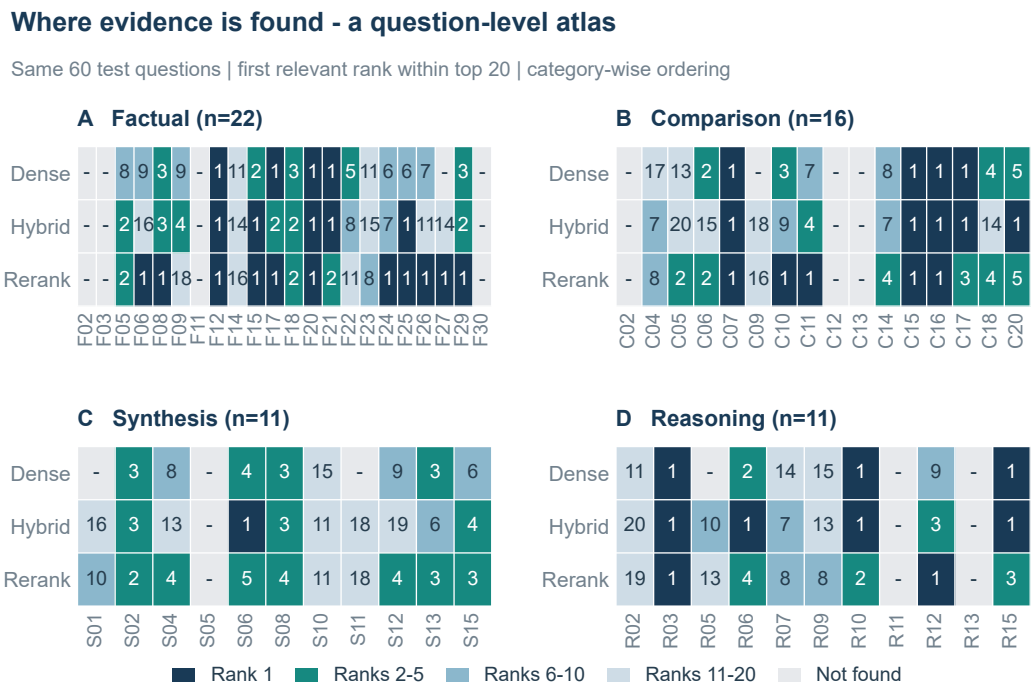


图 14 同 60 题在三种检索模式下的逐题首个相关项名次。题目按四类任务分组，颜色仅对应已检到项；null 表示在保存的候选深度内未检到，不能填充为末位名次。来源 E07。

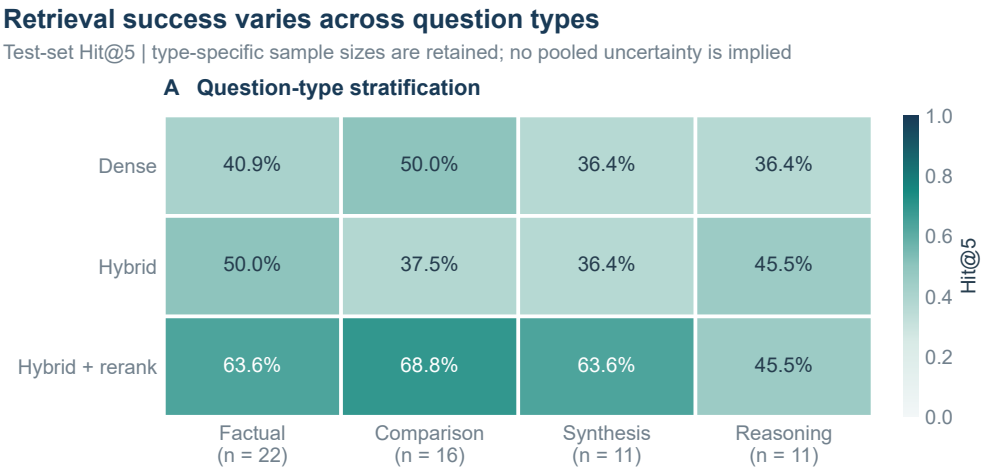


图 15 按事实、比较、综合和推理问题分解的 Hit@5。各类样本量不同；推理题在重排后仍保留较大漏召回空间。来源 E07。

表 17 开发集 RRF 常数与截断深度比较

RRF 常数	评价 K	Hit@K	Recall@K	MRR@20
20	3	0.4000	0.3500	0.324717
20	5	0.4000	0.3500	0.324717
20	10	0.6500	0.5750	0.324717
60	3	0.4000	0.3500	0.314796
60	5	0.4000	0.3500	0.314796
60	10	0.6500	0.5750	0.314796
100	3	0.4000	0.3500	0.314796
100	5	0.4000	0.3500	0.314796
100	10	0.6500	0.5750	0.314796

同 20 个开发集问题，复用实际编码和检索排名，无新增模型调用。MRR 固定在候选深度 20 定义，不随评价 K 重新计算。来源 E08。

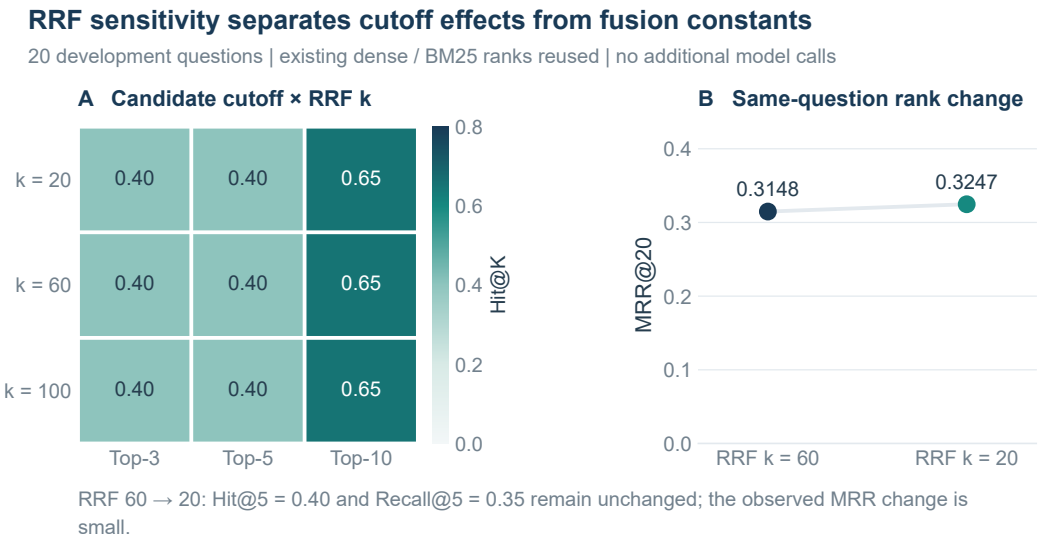


图 16 RRF 常数与评价截断深度的开发集网格。图中分别呈现 Hit@K 与 MRR@20；后者按候选深度 20 计算，不随评价 K 重新定义。来源 E08。

RRF 常数 60 改为 20 后，MRR@20 由 0.314796 变为 0.324717，而 Hit@5 为 0.40、Recall@5 为 0.35，均未变化。该轮实际优化改善了排名，未解决前五条的漏召回；本文保留这一有限改善而不使用“召回显著提高”的表述。

4.10 答案质量生成参数与提示词比较

表 18 60 条实际短答案的 AI 辅助质量评审

维度	均分/5	1 分	2 分	3 分	4 分	5 分
正确性	3.50	5	11	13	11	20
完整性	2.98	4	21	14	14	7
引用支撑	3.03	12	13	13	5	17
流畅性	4.58	0	1	5	12	42

每维 60 条，评分日期 2026 年 10 月 14 日；独立人工评分为 0。1—5 分是有序量表，不是答案准确率，也不是教师课程总分。来源 E09。

四维均分分别为 3.50、2.98、3.03 和 4.58。该分布说明语言流畅不能替代证据覆盖、数值正确及来源支持。评分基于原回答、参考答案、实际引用映射和论文物理页，保留逐题评语，但未开展独立双人

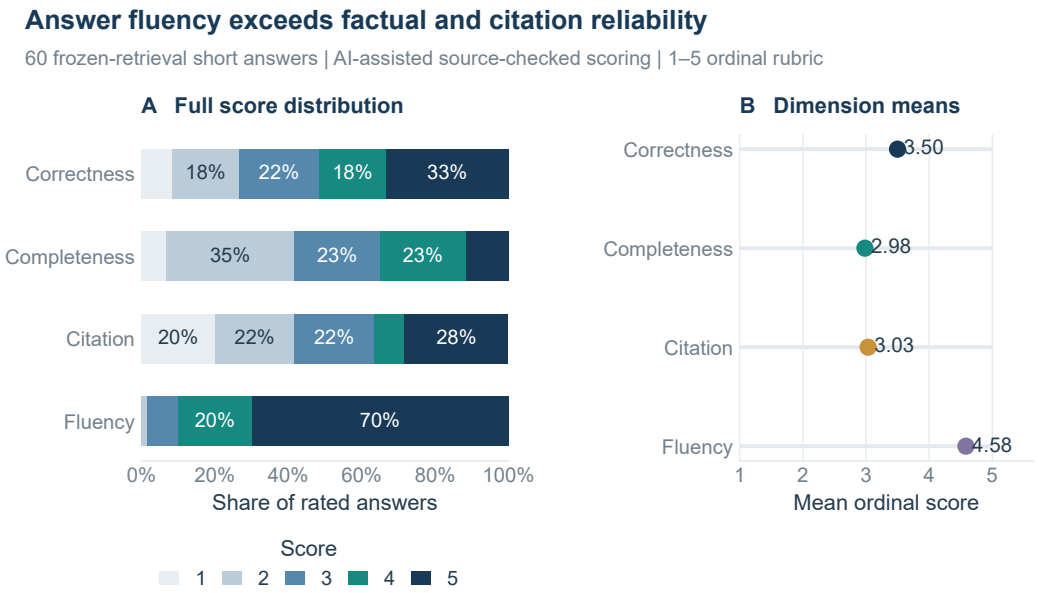


图 17 60 条历史短答案的 AI 辅助量表评审。流畅性明显高于完整性与引用支撑；评分来源为 AI，独立人工评审未执行。来源 E09。

盲评或评分一致性分析。课程原文要求的人工评分不能由 AI 来源标签的替换而得到满足；本文据实将该项列为评价限制。

表 19 四类题目的 AI 辅助分维度均分

题型	n	正确性	完整性	引用支撑	流畅性
事实型	22	3.91	3.41	3.45	4.73
比较型	16	3.06	2.62	2.69	4.56
综合型	11	3.27	2.27	3.36	4.36
推理型	11	3.55	3.36	2.36	4.55

均分范围 1—5，按题目等权计算；四类样本数合计 60。不同题型并非同难度配对任务，不据均分差异推断题型的固有难度。评分来源与表18一致。来源 E09 及派生统计快照。

参数实验合计 20 条真实回答，提示词实验含旧模板 4 条及复用基线的当前模板 4 条。28 个条件记录对应 24 次历史调用，按问题、原回答和引用映射去重后有 17 个独立答案。基线与采样 Top-k 为 20 的条件均值并列，但逐题错误构成不同，不能据此宣布某组参数稳定最优。温度为 0 未消除综合题中的事实错误；较短回答的生成耗时较低，同时受输出长度、模型热身和条件执行顺序混杂。

事实题中，旧回答正确给出 ViT-Base 配置，但引用位置与其自

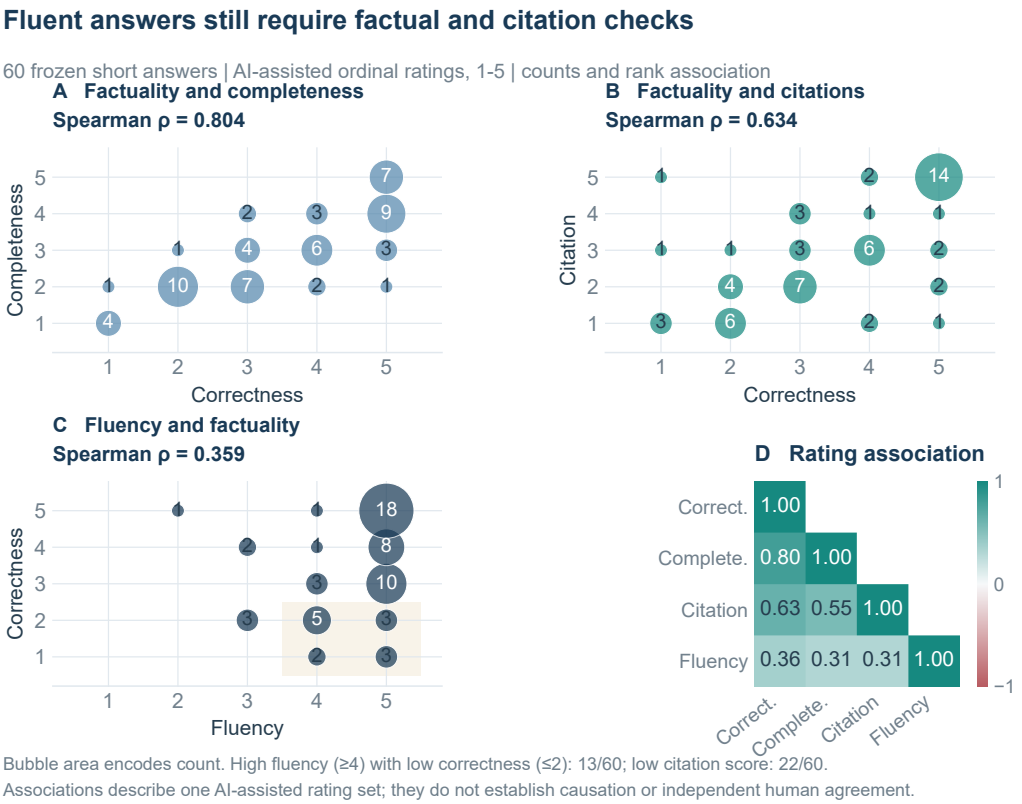


图 18 AI 辅助评分的联合分布与秩相关。气泡依次表示正确性—完整性、正确性—引用支撑、流畅性—正确性的评分组合，面积为题数；热图为 Spearman 相关。其共同变化不证明因果联系或人工评分一致性。来源 E09 及派生统计快照。

表 20 生成参数的质量与成本对比

$T/p/k_s$	正确	完整	引用	流畅	生成/s	输出/条
0.1/0.9/40	**4.25**	**4.00**	**3.50**	**5.00**	3.255	84.25
0.0/0.9/40	3.75	3.75	**3.50**	4.75	2.503	115.00
0.5/0.9/40	3.75	3.50	3.25	**5.00**	1.415	59.50
0.1/0.7/40	3.75	3.50	3.25	**5.00**	1.705	73.25
0.1/0.9/20	**4.25**	**4.00**	**3.50**	**5.00**	1.885	84.25

各条件仅 4 道开发集题，每题单次生成，未固定采样 seed；输出上限 256 token。k_s 为采样 Top-k，与检索返回 Top-K 不同。质量来源为 AI 评审。来源 E10。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

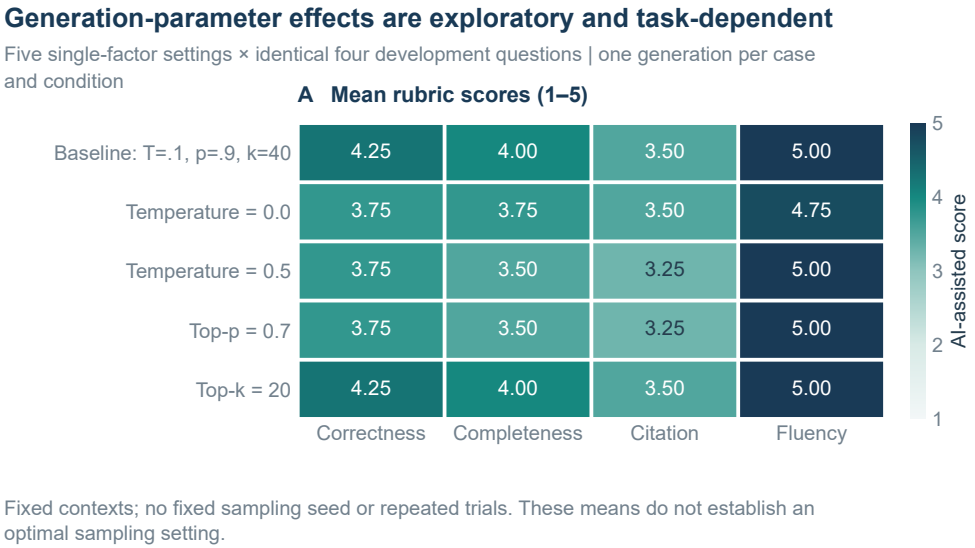


图 19 生成参数条件的四维 AI 评分。每条件 4 题，包含事实、比较、综合和推理；相同输出复用同一评分。来源 E10。

表 21 提示词对照的分维度结果

模板	正确性	完整性	引用支撑	流畅性	生成/s
简化对照	**4.25**	3.75	2.50	**5.00**	3.551
当前证据约束	**4.25**	**4.00**	**3.50**	**5.00**	3.255

每模板 4 条；当前模板复用参数基线回答，不是额外 4 次生成。新旧实验合计 28 个条件记录、24 次历史生成调用、17 个独立答案评审。来源 E10。**粗体**为本表固定口径下的观察最优值（并列保留），不代表总体最优或显著差异。

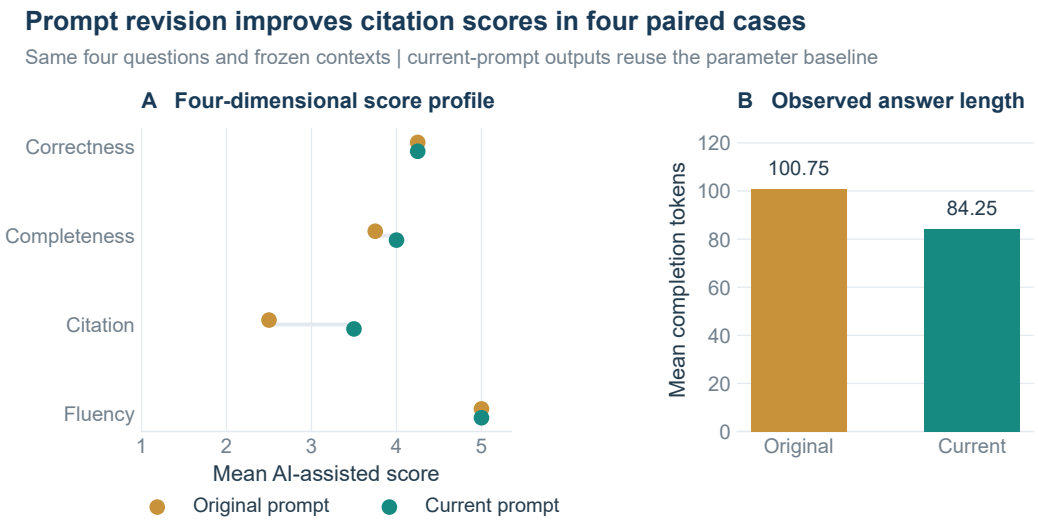


图 20 简化对照与当前证据约束提示词的比较。正确性均值不变，完整性增加 0.25、引用支撑增加 1.00 分；样本不足以支持普遍优势。来源 E10。

写页码不符；当前回答采用实际包含表 1 的来源，改善了引用支撑。另一方面，综合题的冻结 Top5 均来自 T2T，没有 CvT 原文，多个配置仍将普通 ViT 机制错误归给 CvT。该例表明，采样和提示词不能独立修复证据覆盖缺失，应在生成前检验所需论文是否均有可靠来源。

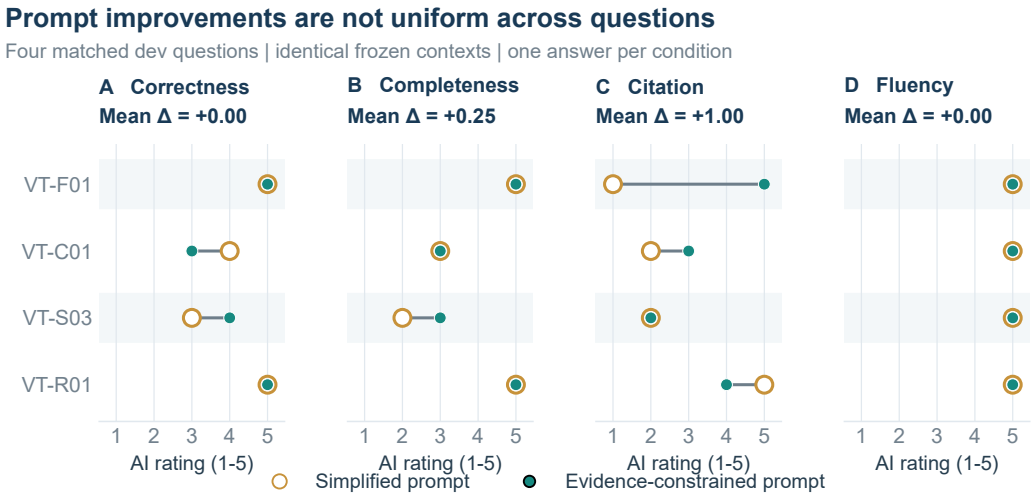


图 21 四题提示词比较的逐题配对分数。连接线对应同一题目，保留改善、持平与退化的实际结果；每题每模板单次生成，不由四题观测推断总体效果。来源 E10 及派生统计快照。

4.11 Agent 效率与本地运行验收

表 22 固定 RAG 与 Agent 探针的实际资源记录

路径	次数	均时/s	P95/s	输入合计	输出合计
固定 RAG	5	1.254	1.958	18105	250
Agent	5	2.481	4.648	10109	469

同 5 个探针、每路径 5 次；Agent 路由 exact-match 为 1.00，仅说明给定探针的工具选择，不等于答案正确率。计时为冻结检索后的生成与工具流程。来源 E11。

固定 RAG 与 Agent 各运行 5 次，Agent 输入 token 合计较少而均时较高，说明减少输入并不保证端到端更快。概念、计算、时间、关键词和论文事实五类探针只覆盖部分路由，不能据此给出全任务成功率。 串行与双线程工具均时为 24.125 与 21.161 ms，未包含 LLM 并发；缓存冷请求 2955.515 ms，精确重复 4.074 ms，后者新增

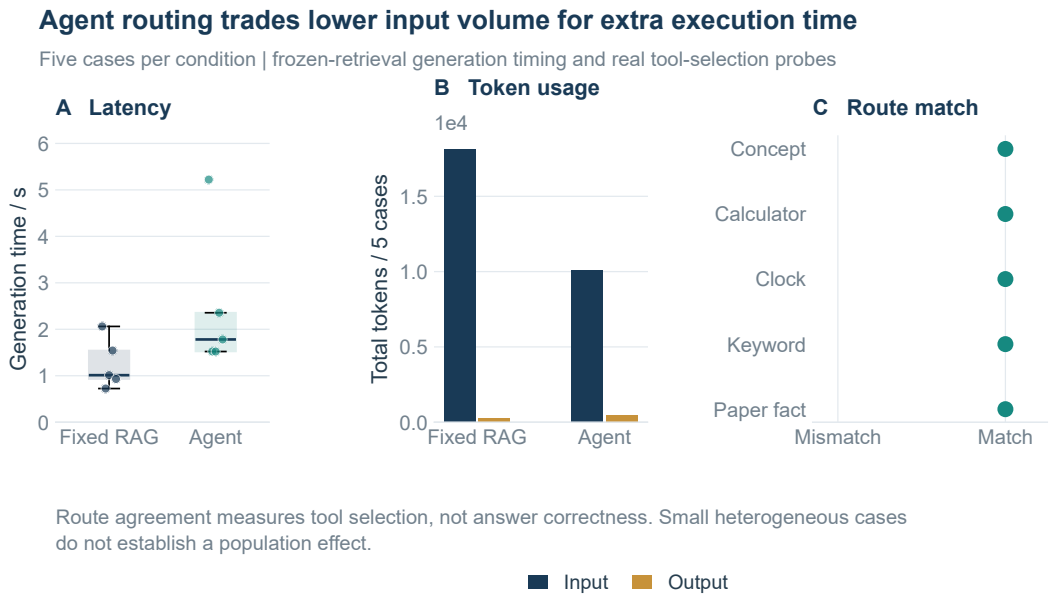


图 22 5 个探针上固定 RAG 与 Agent 的时延和 token 结构。路由匹配为 1.00，不是答案正确率；不同路径的开销组成应分别解释。来源 E11。

表 23 本地工具并行与缓存功能探针

条件	次数	均时/ms	输入 token	输出 token
串行本地工具	10	24.125	0	0
双线程本地工具	10	21.161	0	0
缓存冷请求	1	2955.515	3599	54
精确重复命中	1	4.074	0	0

并行探针不调用 LLM；缓存每条件仅 1 次，不能外推语义近邻命中率或稳定加速倍数。来源 E12。

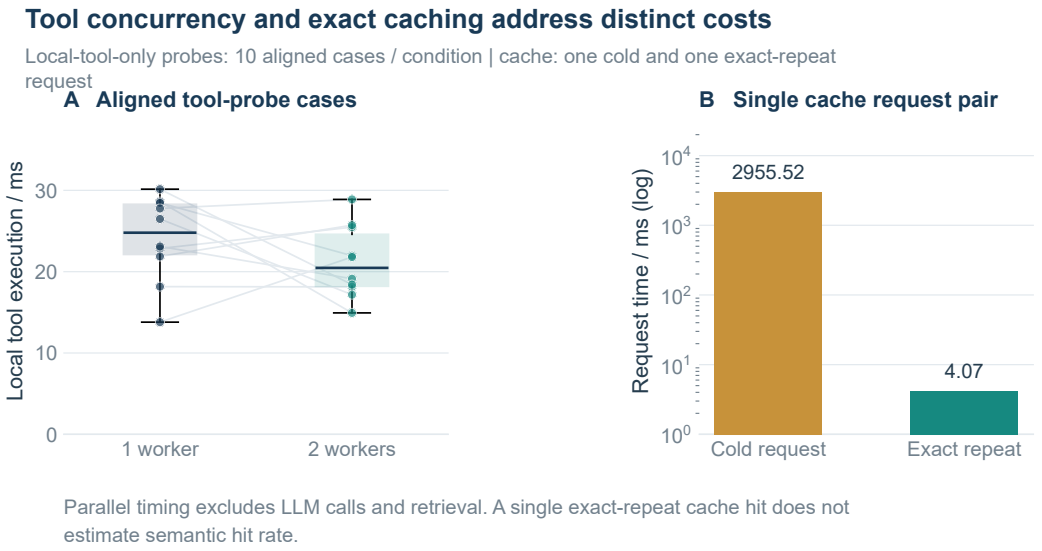


图 23 本地独立工具的串行/双线程配对记录与精确重复缓存探针。缓存使用对数耗时坐标；样本量分别为 10 轮/方式和 1 次/条件。来源 E12。

模型 token 为 0。缓存样例说明功能生效，不作为总体命中率或稳定数百倍加速证据。另有 10 次异质在线诊断请求，平均端到端 52.089 秒，输入/输出合计 43908/4634 token，平均 Agent 步数 1.2；任务不同，不构成同题受控负载测试。

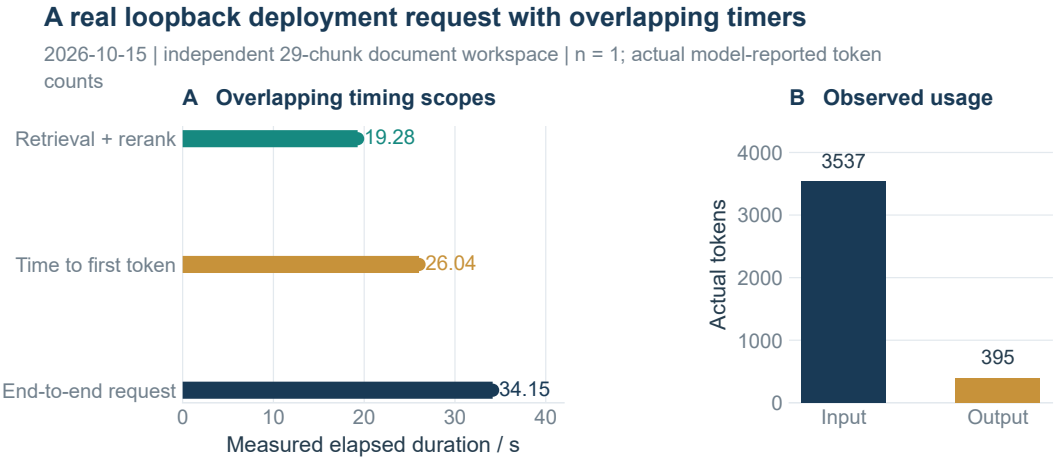


图 24 独立 CvT 本地验收的单次问答资源记录。端到端、检索和首 token 计时互有包含，不能相加；该样例不代表完整题集均值。来源 E14。

本地标准模式实际访问前端 8501、API 8000 和项目模型服务 11435，均绑定 127.0.0.1，保留原系统 11434 服务。验收核对了真

表 24 2026 年 10 月 15 日本地独立流程验收

项目	实际记录
文档与片段	CvT 原文 PDF，独立工作区 29 片段
模型与来源	research-qwen:7b；knowledge_rag
运行状态	33 类检查通过；0 失败
候选与结果	候选 20 条，返回 5 条
端到端问答	34.15 s
检索与重排	19.28 s
首个 token	26.04 s
实际输入/输出	3537 / 395 token
自动审校	5 条待核查提示

正式操作时间为北京时间 17:21:16—17:23:24；33 类检查对应 120 条含轮询的断言记录。这里只验收一次真实流程，不作为完整题集成绩或稳定时延。来源 E14。

实 PDF 上传、29 片段索引、模型 SSE 回答、有效来源编号、原件 SHA-256、引用页 PNG 及会话和调用保存。33 类检查均通过，轮询计入时共有 120 条通过断言；不能把它们写成 120 项独立功能。本次回答仍有 5 条自动审校待核查提示，所以运行通过不表示全部语义正确。

4.12 Bad Case 分析与优化边界

实际问题还包括 Swin 型号与数值错配、PVT 下采样解释、LeViT 结构与 class token 判断、算术错误以及训练条件归属颠倒。这些问题不能仅依靠界面完善或降低温度消除，应优先核验引用覆盖、数值计算来源和跨论文实验条件。除 RRF 同题优化外，结构化比较、服务端页码校正和窗口修复有定向回归或真实样例记录；样例关注点不完全一致时，只作诊断证据而不据其计算因果提升。



图 25 2026 年 10 月 15 日本地页面与模型就绪状态截图。截图仅证明页面加载状态；当日实际新问答以 E14 中的 HTTP、SSE 和调用记录为准。

表 25 四类 Bad Case 与工程输入窗口问题

类型	观察与根因	改进及剩余限制
检索失败	相近架构文本干扰，跨语言实体与跨论文覆盖不足	混合检索和配置探索；RRF 改进只改善 MRR，仍有漏召回
生成错误	自由格式输出、模型补写数值及事实归属错误	schema 与有界修复；格式可用仍不等于语义正确
引用错误	模型自写页码，来源编号与事实对应不严	服务器页码和来源核对；断言语义支持仍需复查
Agent 决策	规划阶段编造文档标识或重复动作	固定明确文档范围、重复与预算终止；探针规模有限
超长窗口	decode/re-encode 导致长度膨胀与输入拒绝	原 token-ID 全覆盖分窗；不宣称等价于无限上下文编码

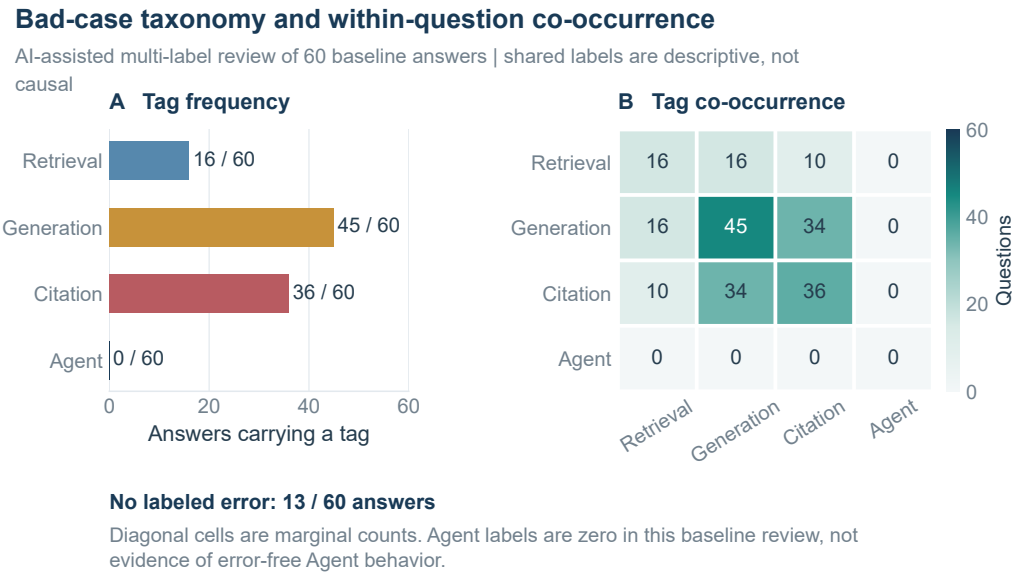


图 26 60 条 AI 评分记录的多标签错误分布。同一回答可同时计入检索、生成和引用错误，因此总数可超过 60；“无明显问题”不等于全面语义认证。来源 E09、E15。

五 技术设计文档

5.1 模块接口与持久化

API 封装文档、任务、会话、运行和实验操作。文档任务状态包括 queued、running、done 与 error；文档就绪后才能进入限定范围的检索。回答、来源、执行事件与配置快照在同一运行记录中保存，便于从界面回到实际调用。部分核心接口见表26，精确 schema 以项目实际 API 文档为准。

5.2 配置与可复现控制

配置由 YAML 和环境变量合并，公开配置排除云端 API 密钥。应用默认上下文、输出、检索和 Agent 预算见表27；不同实验覆盖的值写入各自记录，不从当前默认值倒推历史配置。

表 26 核心接口及数据用途

方法	路径	作用
GET	/health	存活、模型及检索就绪
GET	/config	不含 API 密钥的公开配置
POST	/documents	批量上传及异步索引任务
GET	/jobs/<id>	索引进度和实际错误
GET	/documents/<id>/chunks	分页片段及位置
GET	/documents/<id>/preview	论文物理页预览
POST	/sessions/<id>/chat	SSE 问答与来源事件
GET	/runs/<id>	回答、用量及执行追踪
GET	/sessions/<id>/export	会话导出

表 27 主要配置与实验覆盖关系

配置项	取值	含义与范围
chunk_size/overlap	512/64	轻量分块单位；实验另有 256、1024
candidate_k/result_k	20/5	检索候选与最终来源数量
rrf_k	60	历史基线；开发集另比较 20、100
context_tokens	4096	上下文预算配置，采用保守估算
answer_tokens	768	生产上限；生成研究为 256
temperature/top_p	0.1/0.9	历史基线与实际条件分别记录
top_k_sampling	40	采样参数，不是检索 Top-K
max_agent_steps	6	循环预算
memory_tokens	1400	历史记忆估算预算
memory_recent_messages	8	近期窗口上限
cache_threshold	0.96	还需满足锚点、历史与指纹条件

5.3 隔离错误与安全边界

服务端对文档、会话、运行和实验读取进行工作区归属校验；随机标识提供本地逻辑隔离，不等于完整生产身份认证。上传检查扩展名、空文件及大小，去除文件名路径部分，默认单文件 50 MB、单批 20 份。安全计算器使用白名单 AST；论文正文和工具结果作为数据处理，不赋予其覆盖系统规则的权限。未获得的失败调用用量保留未知，不填零。模型、工具或索引失败通过明确状态、警告及可检查的部分结果呈现。本次部署采用回环地址，不据此推断互联网访问环境下的安全性或并发能力。

5.4 扩展设计的价值与限制

第一项扩展是版本感知的来源与运行记录：编码窗口版本、模型 revision、语料哈希、索引快照与生成配置共同记录，用于识别缓存和实验是否可比。其价值是降低跨版本误用风险，不是对所有历史执行的第三方审计认证。第二项扩展是条件约束的结构化论文比较：对明确论文范围使用服务器标识，优先核对任务、数据集、指标及训练条件，不能确认可比时不计算差值或排名。该设计改善结果组织，但条件抽取和事实核验仍可能出错，需以原文逐项复查。

六 总结与展望

6.1 项目总结

项目完成从多格式论文到可追溯回答的工程链路，并对文档、检索、生成、工具和运行过程建立实际记录。实验支持的主要发现是：在冻结题集和索引条件下，交叉编码器提高前五条证据覆盖，但 CPU 代价明显；分块与 Embedding 不存在被所有指标一致支持的单一最优项；提示词引用约束的收益应按维度和题目解释。本地标准模式的

实际流程可用，并不消除完整性、数值归属和引用支撑方面的质量短板。

6.2 困难与解决过程

文档布局与表格公式导致来源和阅读顺序难以保持，解决思路是统一来源块并保留物理位置，而不是生成不存在的精确结构。超长输入的 decode/re-encode 曾引起窗口膨胀，改用原 ID 分窗后完成实际模型验证。规划动作可能编造文档标识，因而将明确论文范围交由服务器固定，并保留工具失败及恢复路径。引用规则容易把来源存在误当语义正确，本报告将规则审校、量表质量评分和运行成功分别记录，保留未解决的例子。

6.3 研究限制与后续工作

评测仅覆盖一个专题 10 篇论文，题集及其相关性标注由助手整理，尚缺独立人工复核与评分一致性分析；因此外部有效性有限。生成参数每条件 4 题、单次采样且未固定 seed，存在输出长度和运行顺序混杂，不能支持稳定参数最优或显著性结论。历史 359 片段的冻结成绩、342 片段生产语料及 29 片段独立流程验收未构成统一的最新版全题集复测。本地探针不等于并发负载测试，模型回答仍保留待核查项；容器配置已提供，但未完成容器实际验收。

后续优先检查跨论文证据覆盖，在证据缺失时补检索或明确不足，再对数值计算与逐条引用作约束。在更大且经独立复核的题集上重复采样，固定硬件、版本和随机设置，分别评估质量、时延和资源成本。最后再依据受控证据调整默认分块、重排候选规模和采样参数，避免以单一小样本均分替代工程决策。

参考文献

[1] Lewis P, Perez E, Piktus A, et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. Advances in Neural Information Processing Systems, 2020. https://arxiv.org/abs/2005.11401.

[2] Yao S, Zhao J, Yu D, et al. ReAct: Synergizing Reasoning and Acting in Language Models. ICLR, 2023. https://arxiv.org/abs/2210.03629v3.

[3] Robertson S, Zaragoza H. The Probabilistic Relevance Framework: BM25 and Beyond. Foundations and Trends in Information Retrieval, 2009, 3(4):333–389. doi:10.1561/1500000019.

[4] Cormack G V, Clarke C L A, Büttcher S. Reciprocal Rank Fusion outperforms Condorcet and individual Rank Learning Methods. SIGIR, 2009:758–759. doi:10.1145/1571941.1572114.

[5] Chen J, Xiao S, Zhang P, et al. M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation. Findings of ACL, 2024:2318–2335. doi:10.18653/v1/2024.findings-acl.137. https://aclanthology.org/2024.findings-acl.137/.

[6] Dosovitskiy, Alexey; Beyer, Lucas; Kolesnikov, Alexander; et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR, 2021. arXiv:2010.11929v2. https://arxiv.org/abs/2010.11929v2.

[7] Touvron, Hugo; Cord, Matthieu; Douze, Matthijs; et al. Training data-efficient image transformers & distillation through attention. ICML, 2021. arXiv:2012.12877v2. https://arxiv.org/abs/2012.12877v2.

[8] Liu, Ze; Lin, Yutong; Cao, Yue; et al. Swin Transformer: Hierarchical Vision Transformer using Shifted Windows. ICCV, 2021. arXiv:2103.14030v2. https://arxiv.org/abs/2103.14030v2.

[9] Wang, Wenhai; Xie, Enze; Li, Xiang; et al. Pyramid Vision Transformer: A Versatile Backbone for Dense Prediction without Convolutions. ICCV, 2021. arXiv:2102.12122v2. https://arxiv.org/abs/2102.12122v2.

[10] Yuan, Li; Chen, Yunpeng; Wang, Tao; et al. Tokens-to-Token ViT: Training Vision Transformers from Scratch on ImageNet. ICCV, 2021. arXiv:2101.11986v3. https://arxiv.org/abs/2101.11986v3.

[11] Touvron, Hugo; Cord, Matthieu; Sablayrolles, Alexandre; et al. Going deeper with Image Transformers. ICCV, 2021. arXiv:2103.17239v2. https://arxiv.org/abs/2103.17239v2.

[12] Wu, Haiping; Xiao, Bin; Codella, Noel; et al. CvT: Introducing Convolutions to Vision Transformers. ICCV, 2021. arXiv:2103.15808v1. https://arxiv.org/abs/2103.15808v1.

[13] Chen, Chun-Fu; Fan, Quanfu; Panda, Rameswar. CrossViT: Cross-Attention Multi-Scale Vision Transformer for Image Classification. ICCV, 2021. arXiv:2103.14899v2. https://arxiv.org/abs/2103.14899v2.

[14] Graham, Ben; El-Nouby, Alaaeldin; Touvron, Hugo; et al. LeViT: a Vision Transformer in ConvNet's Clothing for Faster Inference. ICCV, 2021. arXiv:2104.01136v2. https://arxiv.org/abs/2104.01136v2.

[15] Bao, Hangbo; Dong, Li; Piao, Songhao; et al. BEiT: BERT Pre-Training of Image Transformers. ICLR, 2022. arXiv:2106.08254v2. https://arxiv.org/abs/2106.08254v2.

七 附录

7.1 实际代码结构与复现环境

```
src/
  core/          config, schemas, storage
  data_loader/   document adapters and source blocks
  chunking/      fixed, recursive, sentence/paragraph splitters
  retrieval/     embeddings, RRF, vector stores, reranking
  generation/    context, prompts, citations, cache, LLM clients
  agent/         registry, router, executor, memory, ReAct loop
  services/      application orchestration
  api/           HTTP and SSE endpoints
  frontend/      Streamlit workspace pages
  evaluation/    datasets, metrics, reviews, exports
scripts/         preparation, execution, reporting, acceptance
tests/           unit, API, frontend, and integration checks
docker/          unverified container deployment configuration
```

表 28 报告整理时记录的本地软件环境

组件	版本	组件	版本
Python	3.12.14	PyTorch	2.14.1
FastAPI	0.142.2	Streamlit	1.65.0
Sentence Transformers	5.7.0	Transformers	5.19.0
Chroma	1.5.9	FAISS CPU	1.15.1
PyMuPDF	1.28.2	NumPy	2.5.3

此表为实际本地环境快照；依赖声明中的版本区间与本表已安装版本不是同一概念。模型权重版本另由 manifest 和指纹记录。

本地运行环境使用 Windows 11 及 NVIDIA GeForce RTX 4060 Laptop GPU；Embedding 与重排配置为 CPU，Ollama 依据资源加载生成模型。仅将软件版本和启动条件作为本机复现信息，不把不同时间的全部实验假设为相同负载或相同模型驻留状态。仓库依赖清单、模型 manifest 与实验快照应联合使用；本报告文件夹只保存文档、图

表和复核数据，不打包模型权重或私有工作区标识。

7.2 本地运行与重新验收

新环境需要 Python 3.10—3.13（建议 3.12）和 Ollama。先在项目根目录安装模型运行依赖，并准备四种实验所需的编码与重排模型：

```
.\scripts\setup.ps1 -Python python -Models
.venv\Scripts\python.exe scripts/prepare_models.py --models BAAI/bge-m3
    BAAI/bge-large-zh-v1.5 moka-ai/m3e-base BAAI/bge-reranker-base --cache-
    dir data/models/hub
```

首次下载需要联网，实际权重 revision 写入`data/models/manifest.json`；严格复现时应使用清单对应的 snapshot，而不是把未来同名仓库视为相同权重。在单独终端设置 Ollama 监听地址后启动服务：

```
$env:OLLAMA_HOST = "127.0.0.1:11435"
ollama serve
```

便携版路径见`data/tools/ollama-manifest.json`。在应用终端指定同一模型服务地址，按固定 GGUF revision 下载、导入并验证生成模型：

```
$env:RAG_OLLAMA_URL = "http://127.0.0.1:11435"
.venv\Scripts\python.exe scripts/prepare_qwen_gguf.py all --ollama-url http
    ://127.0.0.1:11435 --model research-qwen:7b
```

该脚本核对分片 SHA256 并生成`data/models/local-llm.json`，启动器据此选择实际模型标签。模型和缓存已就绪的环境可直接启动；在应用终端执行：

```
.\scripts\start.ps1 -Profile standard -ApiPort 8000 -UiPort 8501 -ModelPort
     11435
.venv\Scripts\python.exe scripts/verify_local_deployment.py --api http
    ://127.0.0.1:8000 --ui http://127.0.0.1:8501 --evidence-dir reports/
    local/new-run --document data/corpus/cvt_2103.15808v1.pdf --timeout 900
```

每次验收使用新随机工作区，保存实际 HTTP 响应、SSE、原件哈希与预览，不复用旧通过标记。首次真实编码和模型加载可能明显慢于后续请求；记录应注明是否命中缓存及实际 token，而不是直接套用表24的单次耗时。

7.3 证据索引与课程要求对应

表 29 报告数值与实现证据索引

编号	内容	项目中的实际位置
E01	固定论文版本	data/corpus/manifest.json
E02	80 题与划分	reports/datasets/dataset_manifest.json
E03	三解析器	reports/experiments/retrieval/parsers/results.json
E04	五分块配置	reports/experiments/retrieval/chunking/m3e/
E05	编码与模型对比	reports/experiments/retrieval/encoding/; reports/experiments/retrieval/chunking/bge-zh/
E06	向量库	reports/experiments/retrieval/vectorstores/
E07	三档 test60	reports/experiments/retrieval/m3/test/
E08	RRF 同题优化	reports/experiments/retrieval/dev-parameters/results.json
E09	60 题 AI 评分	reports/experiments/generation/baseline/ai_review_summary.json 及同目录逐题 CSV
E10	参数与 Prompt	reports/experiments/generation/quality-comparison/；原始记录在reports/experiments/generation/parameters/和reports/experiments/generation/prompt/
E11	Agent 探针	reports/experiments/generation/agent/results.json
E12	并行与缓存	reports/experiments/generation/parallel/和reports/experiments/generation/cache/
E13	异质在线记录	reports/experiments/online-functionality/results.json

编号	内容	项目中的实际位置
E14	本地实际验收	reports/deployment/local-20261015/runtime-record.json 及reports/deployment/local-20261015/acceptance/acceptance.json
E15	Bad Case	reports/experiments/bad-cases/actual-bad-cases.json
E16	已有测试记录	reports/testing/；完整与定向测试时间分别保存，不叠加重叠数量
E17	历史界面图	docs/screenshots/；本文件夹保留原件及图表来源指纹

本报告文件夹中的data/report-data.json 保存原始制表与绘图快照，data/advanced-statistics.json 保存同题配对效果和评分分组等派生统计，figures/figure_manifest.json 记录图形及截图来源。课程要求中的多格式解析、三分块、两编码模型、三档检索、生成参数、八工具及四类 Bad Case 分别在第三、四部分对应展开。原文的独立人工评分与容器实测尚无完成证据，未因本报告采用 AI 评审和本地部署而改写为已完成。

7.4 图表与源文件编译

main.tex 为完整正文源文件，参考文献内嵌，不依赖外部 BibTeX；所有图像均从本文件夹的figures/ 相对引用。建议使用 XeLaTeX 连续编译两次，或使用支持 XeTeX 的 Tectonic；中文字体采用 TeX 发行版提供的 Fandol 仿宋，避免依赖仅存在于本机的中文字体。图表包含矢量 PDF 与可预览的高分辨率 PNG，原始界面图片保留在figures/original-ui/，标注只说明功能区域，不修改界面内容。正文按模板采用仿宋四号、1.5 倍行距及 A4 页边距；图注和结果表适度缩小，以保证图、文和数据的可读性。