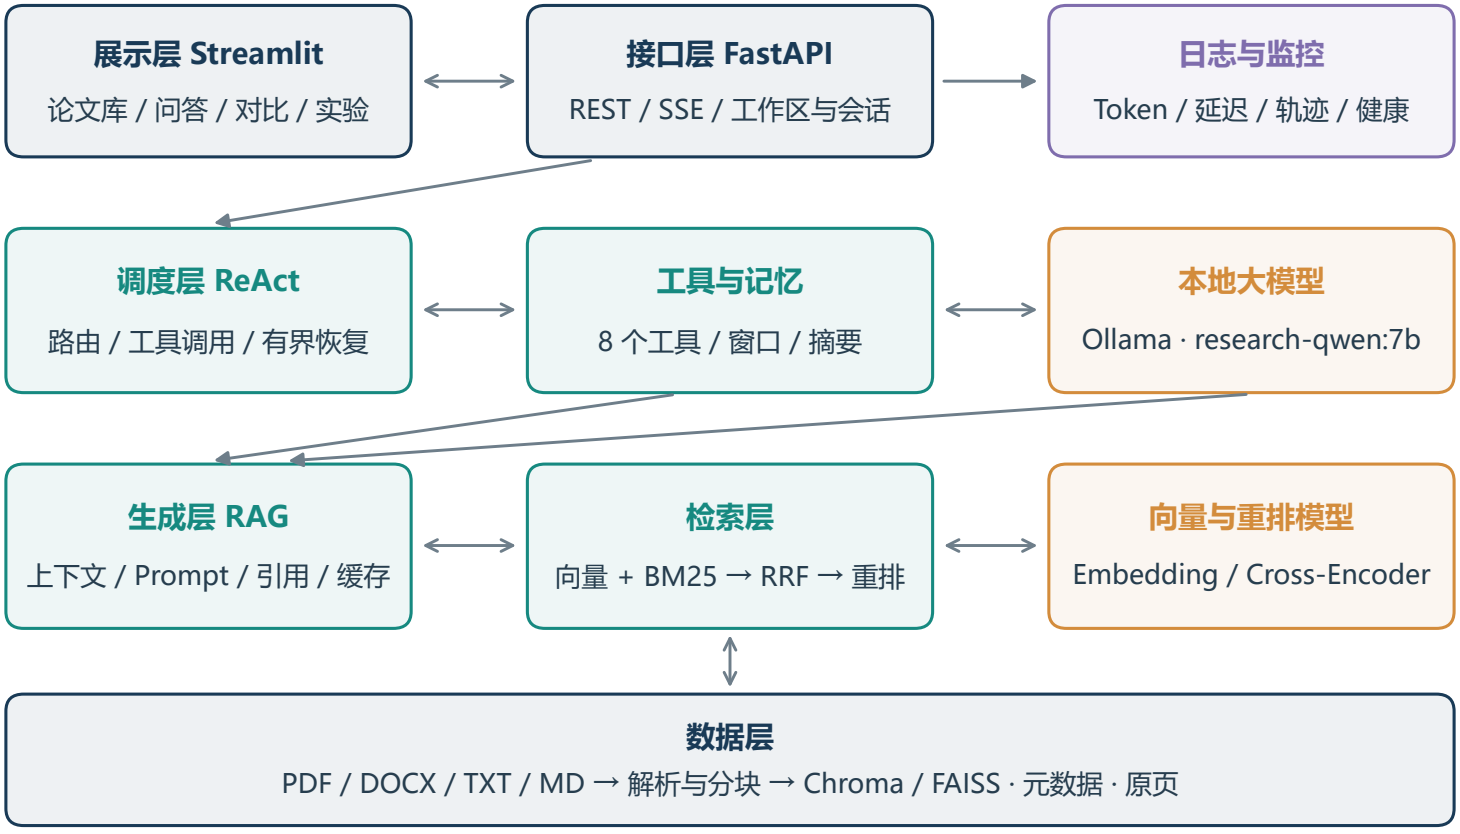

展示层 Streamlit
论文库 / 问答 / 对比 / 实验
接口层 FastAPI
REST / SSE / 工作区与会话
日志与监控
Token / 延迟 / 轨迹 / 健康
调度层 ReAct
路由 / 工具调用 / 有界恢复
工具与记忆
8 个工具 / 窗口 / 摘要
本地大模型
Ollama · research-qwen:7b
生成层 RAG
上下文 / Prompt / 引用 / 缓存
检索层
向量 + BM25 → RRF → 重排
向量与重排模型
Embedding / Cross-Encoder
数据层
PDF / DOCX / TXT / MD → 解析与分块 → Chroma / FAISS · 元数据 · 原页